

Étude de la métrique de Fisher–Rao sur trois sous-variétés riemanniennes du cône des matrices symétriques définies positives

CASSIM Shayck , AHRIZ Marouane

Résumé

Estimer une matrice de covariance à un facteur d'échelle près conduit à travailler sur une variété plutôt que dans un espace vectoriel, où la notion même d'orthogonalité dépend de la métrique choisie. Ce rapport traite le problème de bout en bout, en trois temps.

La première partie met en place le cadre géométrique : caractérisation des espaces tangents, projections orthogonales explicites et construction de l'information de Fisher, pour trois contraintes d'échelle classiques et deux métriques riemanniennes. Elle établit également que la projection sur l'espace tangent approche le logarithme riemannien au premier ordre, ce qui garantit que la borne évaluée numériquement ne dépend pas du choix de métrique à l'ordre pertinent.

La deuxième partie présente la méthodologie de validation numérique : estimateurs considérés, fonction de coût, gradient ambiant, projection tangente, rétraction, et les trois algorithmes d'optimisation retenus.

La troisième partie présente et analyse les résultats. Les simulations de Monte-Carlo valident l'inégalité de Cramér–Rao intrinsèque dans le cas gaussien, établissent que la métrique de Fisher–Rao absorbe une part importante de la dégradation liée au mauvais conditionnement, et montrent que la hiérarchie des contraintes d'échelle dépend du régime d'optimisation, la contrainte du déterminant s'imposant comme la plus robuste.

Table des matières

I	Cadre géométrique : sous-variétés de forme, métriques et information de Fisher	4
1	Introduction et notations	4
1.1	Conventions sur les notations	4
1.2	Les variétés étudiées	4
1.3	Espace tangent de la sous-variété contrainte	5
2	Les deux produits scalaires sur l'espace tangent	5
2.1	Le produit scalaire euclidien	5
2.2	Le produit scalaire de Fisher–Rao paramétrique	5
2.3	Condition sur α pour un produit scalaire	5
3	Construction d'une base de l'espace tangent	6
3.1	Paramétrisation par les entrées libres	6
3.2	Les trois matrices K , D , M	6

4	Projections orthogonales sur la sous-variété contrainte	7
4.1	Contrainte $S_1(\Sigma) = [\Sigma]_{11}$	7
4.2	Contrainte $S_2(\Sigma) = \text{tr}(\Sigma)/m$	8
4.3	Contrainte $S_3(\Sigma) = \Sigma ^{1/m}$	9
4.4	Bilan des projections	9
5	La matrice d'information de Fisher comme espérance de différentielles	10
5.1	Pourquoi éviter la formulation par produit scalaire	10
5.2	La formulation retenue	10
6	Modèle RES et forme bilinéaire de Fisher	10
6.1	Lois RES : densité et représentation stochastique	10
6.2	Différentielle du score	11
6.3	Le score est centré	11
6.4	La forme bilinéaire de Fisher	12
6.5	Validité sur $\mathcal{S}_m$ tout entier	13
7	Bases orthonormées et assemblage de $P_{\mathcal{E}}(V)$ et $F(V)$	13
7.1	Procédure générale de calcul	13
7.2	Contrainte S_1 : les deux bases et $P_{\mathcal{E}}(V)$	14
7.3	Contrainte S_1 : calcul numérique de $P_{\mathcal{E}}(V)$ pour la métrique de Fisher–Rao	15
7.4	Contrainte S_2 : gradient de la contrainte et base tangente	16
7.5	Contrainte S_2 : produits scalaires euclidiens et orthogonalité	16
7.6	Contrainte S_2 : la matrice de projection	17
8	Approximation du logarithme riemannien	17
8.1	Pourquoi approximer le logarithme riemannien	17
8.2	La projection approche le logarithme riemannien	18
8.3	Cohérence des deux projections	19
	Bilan de la partie théorique	20
II	Méthodologie numérique et algorithmes d'estimation	20
9	Présentation du problème	21
9.1	Cadre statistique et géométrie	21
9.2	La borne que l'on cherche à vérifier	21
9.3	Pourquoi comparer plusieurs contraintes	21
10	L'estimateur naturel	22
11	Éléments de calcul pour l'optimisation	22
11.1	De la vraisemblance à la fonction de coût	22
11.2	Maximiser L revient à minimiser f	23
11.3	Calcul du gradient ambiant	23
11.4	Projection orthogonale et gradient riemannien	23
12	Critères d'évaluation et de comparaison	25
12.1	Covariance empirique des estimateurs	25
12.2	Matrice d'information de Fisher	25
12.3	Comparaison avec la borne	26

13 Maximum de vraisemblance par descente de gradient euclidienne	26
13.1 Principe et rôle du pas	26
13.2 Choix du pas par backtracking	27
13.3 Insuffisance de la descente euclidienne naïve	27
14 Maximum de vraisemblance par descente de gradient stochastique	27
14.1 Du gradient complet au gradient stochastique	27
14.2 Gradient de mini-batch	27
14.3 Adaptation géométrique	27
15 Maximum de vraisemblance par descente de gradient naturel	28
15.1 Le gradient dépend de la métrique choisie	28
15.2 Le gradient naturel	28
15.3 Comparaison avec la descente classique	28
15.4 Adaptation géométrique et réglages	29
III Résultats numériques et comparaison des estimateurs	29
16 Méthodologie de l'analyse et grille de lecture	29
16.1 L'écart relatif comme unique critère	29
16.2 Ordre de grandeur du bruit de Monte-Carlo	29
16.3 Grille de lecture	30
17 Estimateur naturel	30
17.1 Écart relatif et comportement asymptotique	30
17.2 Influence de la contrainte géométrique	31
17.3 Dynamique de convergence et stabilité	32
18 MLE par descente de gradient euclidienne	32
18.1 Écart relatif et comportement asymptotique	32
18.2 Influence de la contrainte géométrique	33
18.3 Dynamique de convergence et stabilité	33
19 MLE par descente de gradient stochastique	34
19.1 Écart relatif et comportement asymptotique	34
19.2 Influence de la contrainte géométrique	35
19.3 Dynamique de convergence, stabilité et influence du pas	36
20 MLE par descente de gradient naturel	37
20.1 Écart relatif et comportement asymptotique	37
20.2 Influence de la contrainte géométrique	38
20.3 Dynamique de convergence et stabilité	39
21 Comparaison de l'évolution des quatre estimateurs sur un même graphique	40
21.1 Lecture par les courbes	40
21.2 Contrainte S_1	40
21.3 Contrainte S_2	40
21.4 Contrainte S_3	41
22 Conclusion expérimentale	42
Conclusion générale	42

Première partie

Cadre géométrique : sous-variétés de forme, métriques et information de Fisher

1 Introduction et notations

1.1 Conventions sur les notations

Les quantités scalaires sont notées en italique (a), les vecteurs colonnes en gras minuscule ($\mathbf{a}$) et les matrices en majuscule (A). L'entrée (i, j) d'une matrice A est notée indifféremment $[A]_{ij}$ ou a_{ij} . On note $A^\top$ la transposée, A^{-1} l'inverse et $A^{-1/2}$ une racine carrée de A^{-1} , définie pour toute matrice A symétrique définie positive. La trace est notée $\text{tr}(\cdot)$, le déterminant $|\cdot|$, et I_m désigne la matrice identité de taille m .

Les opérateurs de vectorisation jouent un rôle central : $\text{vec}(A)$ empile les colonnes de A en un vecteur de dimension m^2 , tandis que $\text{vecs}(A)$ empile les entrées de la partie triangulaire inférieure d'une matrice symétrique en un vecteur de dimension $m(m+1)/2$. La matrice de duplication D_m relie ces deux représentations : $D_m \text{vecs}(A) = \text{vec}(A)$ pour toute matrice symétrique A . Enfin, $\widetilde{\text{vecs}}(A)$ désigne le vecteur $\text{vecs}(A)$ privé de sa première composante, de sorte que

$$\text{vecs}(A) = (a_{11}, \widetilde{\text{vecs}}(A)^\top)^\top.$$

1.2 Les variétés étudiées

Nous étudierons deux variétés liées.

- $\mathcal{S}_m^+$ est la variété des matrices $m \times m$ symétriques définies positives. C'est le cône ouvert dans lequel vivent les matrices de dispersion (notion des lois RES présentées plus loin). En tout point Σ , son espace tangent est l'espace vectoriel $\mathcal{S}_m$ des matrices symétriques :

$$T_\Sigma \mathcal{S}_m^+ = \mathcal{S}_m, \quad \dim \mathcal{S}_m = d \triangleq \frac{m(m+1)}{2}.$$

- $\mathcal{S}_{m,S}^+$ est la sous-variété contrainte, obtenue en imposant une contrainte d'échelle :

$$\mathcal{S}_{m,S}^+ \triangleq \{V \in \mathcal{S}_m^+ \mid S(V) = 1\}, \quad \dim \mathcal{S}_{m,S}^+ = p \triangleq d - 1 = \frac{m(m+1)}{2} - 1.$$

La fonction d'échelle $S : \mathcal{S}_m^+ \rightarrow \mathbb{R}^+$ satisfait trois hypothèses structurantes :

- (A1) homogénéité d'ordre un, $S(c\Sigma) = cS(\Sigma)$ pour tout $c > 0$;
- (A2) différentiabilité avec $\partial S(\Sigma)/\partial[\Sigma]_{11} \neq 0$;
- (A3) normalisation $S(I_m) = 1$.

La *matrice de forme* associée à une matrice de dispersion Σ est alors

$$V = \frac{\Sigma}{S(\Sigma)} \in \mathcal{S}_{m,S}^+. \quad (1)$$

On étudiera les trois choix classiques, que l'on notera dès à présent S_1 , S_2 et S_3 afin de disposer d'une notation unique dans tout le rapport :

$$S_1(\Sigma) = [\Sigma]_{11}, \quad S_2(\Sigma) = \frac{\text{tr}(\Sigma)}{m}, \quad S_3(\Sigma) = |\Sigma|^{1/m}. \quad (2)$$

1.3 Espace tangent de la sous-variété contrainte

La sous-variété $\mathcal{S}_{m,S}^+$ est le lieu d'annulation de la fonction différentiable $F(V) = S(V) - 1$. Considérons une courbe lisse $V(t)$ tracée sur $\mathcal{S}_{m,S}^+$, avec $V(0) = V$. Puisque $S(V(t)) = 1$ pour tout t , la dérivation en $t = 0$ donne $dS(V)[\dot{V}(0)] = 0$. En posant $W \triangleq \dot{V}(0)$, on obtient la caractérisation de l'espace tangent en un point V :

$$T_V \mathcal{S}_{m,S}^+ = \{W \in \mathcal{S}_m \mid dS(V)[W] = 0\}, \quad (3)$$

où $dS(V)[\cdot]$ est la différentielle de la fonction d'échelle. Pour les trois choix (2), cette condition se lit respectivement

$$[W]_{11} = 0, \quad \text{tr}(W) = 0, \quad \text{tr}(V^{-1}W) = 0. \quad (4)$$

2 Les deux produits scalaires sur l'espace tangent

L'espace tangent $T_V \mathcal{S}_{m,S}^+$ peut être muni de différentes métriques riemanniennes. Deux d'entre elles gouvernent toute la suite : la métrique euclidienne, la plus simple, et la métrique de Fisher–Rao paramétrique.

2.1 Le produit scalaire euclidien

Le produit scalaire euclidien (ou de Frobenius) sur $\mathcal{S}_m$ est celui induit par la trace :

$$\langle A, B \rangle_V = \text{tr}(A^\top B) = \sum_{i,j} A_{ij} B_{ij}, \quad A, B \in \mathcal{S}_m. \quad (5)$$

Il ne dépend pas du point V : la géométrie qu'il définit est plate. C'est le choix de référence, celui pour lequel l'orthogonalité coïncide avec l'intuition matricielle usuelle.

2.2 Le produit scalaire de Fisher–Rao paramétrique

La métrique de Fisher–Rao paramétrique, en revanche, dépend explicitement du point V via son inverse V^{-1} , et fait intervenir un paramètre réel α :

$$\langle A, B \rangle_V = \frac{\alpha}{2} \text{tr}(V^{-1} A V^{-1} B) + \frac{\alpha - 1}{4} \text{tr}(V^{-1} A) \text{tr}(V^{-1} B). \quad (6)$$

Attention. Cette métrique n'est un véritable produit scalaire que sous une condition sur α , établie au §2.3 ci-dessous (pour la définie-positivité) ; cf. [1].

Remarque 2.1. Le passage de (5) à (6) revient à « pondérer » chaque direction tangente par la matrice V^{-1} . Deux matrices orthogonales au sens euclidien ne le sont plus, en général, au sens de Fisher–Rao : l'orthogonalité est « tordue » par la géométrie locale du cône. C'est cette torsion qui rendra le calcul de la projection plus délicat dans le second cas, difficulté à laquelle on fait face dans les résolutions qui suivent.

2.3 Condition sur α pour un produit scalaire

Pour que la forme (6) soit un véritable produit scalaire, il faut $\langle A, A \rangle_V > 0$ pour toute matrice $A \in \mathcal{S}_m \setminus \{0\}$. Le changement de variable $W = V^{-1/2} A V^{-1/2}$ (licite car V^{-1} est définie positive) ramène la condition à

$$\frac{\alpha}{2} \text{tr}(W^2) + \frac{\alpha - 1}{4} (\text{tr} W)^2 > 0.$$

Le résultat est clair pour $\alpha > 1$. Sinon, en introduisant le spectre $\{\lambda_i\}_{i=1}^m$ de W et l'inégalité de Cauchy–Schwarz $(\sum_i \lambda_i)^2 \leq m \sum_i \lambda_i^2$, le cas défavorable ($W \propto I_m$) fournit la condition

$$\alpha > \frac{m}{m+2}. \quad (7)$$

3 Construction d'une base de l'espace tangent

On décrit ici la méthodologie produisant une base explicite de $T_V \mathcal{S}_{m,S}^+$. Elle n'est pas requise pour le calcul des projections de la section 4, qui repose uniquement sur l'identification d'une direction normale; elle deviendra en revanche indispensable dès que l'on voudra assembler la matrice d'information de Fisher. On la présente donc comme socle des développements qui suivront.

3.1 Paramétrisation par les entrées libres

La sous-variété $\mathcal{S}_{m,S}^+$ résulte d'une contrainte scalaire imposée à une matrice symétrique. Sans contrainte, une telle matrice possède $d = m(m+1)/2$ entrées libres, rangées dans $\text{vecs}(V)$. La contrainte en bloque une : par l'hypothèse (A2), le théorème des fonctions implicites permet d'exprimer l'entrée $(1,1)$ en fonction des $p = d - 1$ autres,

$$[V]_{11} = f(\widetilde{\text{vecs}}(V)),$$

de sorte que le vecteur des paramètres libres est $v \triangleq \widetilde{\text{vecs}}(V) \in \mathbb{R}^p$ (toutes les entrées de $\text{vecs}(V)$ sauf la première).

3.2 Les trois matrices K , D , M

Trois matrices articulent le passage des paramètres libres aux vecteurs tangents.

- La **matrice de duplication** D_m (taille $m^2 \times d$) dépie la représentation compacte en la représentation complète, $D_m \text{vecs}(A) = \text{vec}(A)$. Elle réalise un simple changement de représentation, en dupliquant les entrées hors-diagonale.
- La matrice K_S^V (taille $d \times p$) est la jacobienne de la paramétrisation $v \mapsto \text{vecs}(V(v))$. Elle s'écrit par blocs

$$K_S^V = \begin{pmatrix} \nabla_{\widetilde{\text{vecs}}(V)}^\top [V]_{11} \\ I_p \end{pmatrix},$$

où le bloc inférieur I_p traduit la variation triviale des entrées libres, et la première ligne encode la réaction de l'entrée contrainte $[V]_{11}$ via la fonction implicite f .

- La matrice M_S^V (taille $p \times m^2$), définie par $M_S^V = (K_S^V)^\top D_m^\top$, est la jacobienne de la paramétrisation vue dans l'espace $\mathbb{R}^{m^2}$. Ses lignes sont exactement les vecteurs tangents « mis à plat » : $[M_S^V]_{j,\cdot} = \text{vec}(\Xi_j^0)^\top$, avec, comme dans le document de référence [2] (éq. (31)),

$$\Xi_j^0 \triangleq \left. \frac{\partial V(v)}{\partial v_j} \right|_{v=v_0}.$$

Par la règle de la chaîne, chaque Ξ_j^0 vérifie $dS(V)[\Xi_j^0] = 0$ et appartient donc à $T_V \mathcal{S}_{m,S}^+$. La famille $\mathcal{E}_V = \{\Xi_i\}_{i=1}^p$, dont on montre ci-dessous qu'elle est libre, constitue alors une base de l'espace tangent.

Proposition 3.1. *La famille $\mathcal{E}_V = \{\Xi_i\}_{i=1}^p$, où $\Xi_i = \partial V(v)/\partial v_i|_{v=v_0}$, est une base de $T_V \mathcal{S}_{m,S}^+$.*

Démonstration. On procède en deux temps : le cardinal, puis l'indépendance linéaire.

(i) *Cardinal.* On a déjà établi que chaque Ξ_i appartient à $T_V \mathcal{S}_{m,S}^+$ et que $\dim T_V \mathcal{S}_{m,S}^+ = p$. La famille compte exactement $p = \dim v_0 = m(m+1)/2 - 1$ éléments : c'est donc le bon nombre de vecteurs pour former une base; il reste à vérifier qu'ils sont linéairement indépendants.

(ii) *Indépendance linéaire.* Considérons une combinaison linéaire nulle

$$\sum_{i=1}^p a_i \Xi_i = 0, \quad a = (a_1, \dots, a_p) \in \mathbb{R}^p.$$

Par définition de Ξ_i , cette somme n'est autre que la dérivée directionnelle de la paramétrisation le long de a :

$$\sum_{i=1}^p a_i \Xi_i = \left. \frac{d}{dt} V(v_0 + t a) \right|_{t=0} = 0.$$

Autrement dit, se déplacer dans la direction a de l'espace des paramètres ne modifie pas V au premier ordre. Or, sous les hypothèses (A1)–(A3), la paramétrisation $v \mapsto V(v)$ est localement identifiable : sa jacobienne M_S^V est de rang plein p . Le seul vecteur annulant cette dérivée directionnelle est donc $a = 0$, c'est-à-dire $a_i = 0$ pour tout i . Les matrices $\{\Xi_i\}_{i=1}^p$ sont ainsi linéairement indépendantes.

De (i) et (ii), $\mathcal{E}_V$ est une famille libre de cardinal $\dim T_V \mathcal{S}_{m,S}^+$: c'est une base de $T_V \mathcal{S}_{m,S}^+$. $\square$

Matrice	Taille	Rôle
D_m	$m^2 \times d$	Duplique les entrées : $\text{vecs}(\cdot) \rightarrow \text{vec}(\cdot)$
K_S^V	$d \times p$	Jacobienne $v \mapsto \text{vecs}(V)$
M_S^V	$p \times m^2$	Lignes = $\text{vec}(\Xi_j^0)^\top$; base de $T_V \mathcal{S}_{m,S}^+$ à plat

4 Projections orthogonales sur la sous-variété contrainte

On cherche, pour une matrice symétrique générique $X \in \mathcal{S}_m$, sa projection orthogonale sur l'espace tangent $T_V \mathcal{S}_{m,S}^+$, dans les deux métriques et pour les trois fonctions d'échelle. Dans chaque cas, l'espace tangent est un hyperplan de $\mathcal{S}_m$ défini par l'annulation d'une forme linéaire (cf. (4)) ; son complémentaire orthogonal est donc une droite engendrée par une direction normale N .

Précisons la notation, car deux projections orthogonales distinctes entrent en jeu. On note $P_{(T_V \mathcal{S}_{m,S}^+)^\perp}^{g_V}(X)$ la projection orthogonale de X sur la droite normale $\text{vect}(N)$, c'est-à-dire la composante de X le long de N :

$$P_{(T_V \mathcal{S}_{m,S}^+)^\perp}^{g_V}(X) = \frac{\langle N, X \rangle_V}{\|N\|_V^2} N. \quad (8)$$

L'exposant g_V rappelle que l'orthogonalité est entendue au sens de la métrique $\langle \cdot, \cdot \rangle_V$ choisie. La projection orthogonale de X sur l'espace tangent $T_V \mathcal{S}_{m,S}^+$ lui-même s'obtient alors en retranchant cette composante :

$$P_{T_V \mathcal{S}_{m,S}^+}^{g_V}(X) = X - P_{(T_V \mathcal{S}_{m,S}^+)^\perp}^{g_V}(X). \quad (9)$$

Tout le travail consiste à identifier N .

Remarque 4.1. Aucune base n'est nécessaire ici. Chaque contrainte de (4) ne porte que sur une forme linéaire scalaire : l'espace tangent est un hyperplan et son orthogonal est une droite. Il est donc plus direct de raisonner sur la direction normale que de manipuler les p vecteurs de base Ξ_i . Les matrices K , D , M de la section 3 n'interviendront que lorsqu'il faudra s'intéresser à la matrice d'information de Fisher.

4.1 Contrainte $S_1(\Sigma) = [\Sigma]_{11}$

Ici $T_V \mathcal{S}_{m,S}^+ = \{W \in \mathcal{S}_m \mid [W]_{11} = 0\}$, hyperplan défini par la forme $W \mapsto [W]_{11} = \text{tr}(E_{11}W)$, où $E_{11} = e_1 e_1^\top$ est la matrice canonique dont la seule entrée non nulle, en position $(1, 1)$, vaut 1.

Cas euclidien. La direction normale est l'unique (à un scalaire près) matrice N telle que $\text{tr}(N^\top W) = 0$ pour toute W d'entrée $(1, 1)$ nulle. C'est manifestement $N = E_{11}$, donc $(T_V \mathcal{S}_{m,S}^+)^\perp = \text{vect}(E_{11})$. En reportant dans (8) avec $\|E_{11}\|_V^2 = \text{tr}(E_{11}^\top E_{11}) = 1$ et $\langle E_{11}, X \rangle_V = \text{tr}(E_{11}X) = X_{11}$:

$$P_{(T_V \mathcal{S}_{m,S}^+)^\perp}^{g_V}(X) = X_{11} E_{11}, \quad \text{d'où} \quad P_{T_V \mathcal{S}_{m,S}^+}^{g_V}(X) = X - X_{11} E_{11}.$$

La projection sur l'espace tangent annule l'entrée $(1, 1)$ de X , toutes les autres restant inchangées.

Cas de la métrique de Fisher–Rao. La direction normale n'est plus E_{11} : le produit scalaire fait intervenir V^{-1} , ce qui déforme l'orthogonalité. On cherche N sous une forme « naïve », corrigée par un terme scalaire :

$$N = VE_{11}V - kV, \quad (10)$$

où $VE_{11}V$ est le candidat naturel (l'image de E_{11} transportée par la métrique) et $k \in \mathbb{R}$ est ajusté pour rendre N orthogonale à tout $T_V \mathcal{S}_{m,S}^+$. Autrement dit, le premier terme de N annule celui de la métrique ; il reste donc le second terme, que l'on doit compenser par le terme en kV . En imposant $\langle N, W \rangle_V = 0$ pour toute $W \in T_V \mathcal{S}_{m,S}^+$ et en regroupant les termes, la condition se réduit à une équation scalaire linéaire en k , de solution

$$k = \frac{(\alpha - 1)V_{11}}{2\alpha + (\alpha - 1)m}. \quad (11)$$

En reportant (11) dans (10) et en utilisant $V_{11} = 1$ (puisque $V \in \mathcal{S}_{m,S}^+$ pour cette contrainte),

$$N = VE_{11}V - \frac{\alpha - 1}{\alpha(m + 2) - m} V, \quad (12)$$

la projection sur la normale étant $P_{(T_V \mathcal{S}_{m,S}^+)^{\perp}}^{gV}(X) = \frac{\langle N, X \rangle_V}{\|N\|_V^2} N$ et la projection sur l'espace tangent $X - P_{(T_V \mathcal{S}_{m,S}^+)^{\perp}}^{gV}(X)$.

Remarque 4.2. Sur la norme de N : le dénominateur $\|N\|_V^2 = \langle N, N \rangle_V$ est une constante ne dépendant que de la dimension m et du paramètre α ; on la notera $\|N\|_V^2 = C_{m,\alpha}$. Son expression explicite s'obtient en développant (6) sur la matrice (12) ; on la calculera au besoin, c'est-à-dire uniquement lorsque la valeur numérique de la projection sera requise. Pour la structure du résultat, seule importe l'existence de cette constante strictement positive.

4.2 Contrainte $S_2(\Sigma) = \text{tr}(\Sigma)/m$

Ici $dS(\Sigma)[W] = \text{tr}(W)/m$, donc $T_V \mathcal{S}_{m,S}^+ = \{W \in \mathcal{S}_m \mid \text{tr}(W) = 0\}$: c'est l'hyperplan des matrices symétriques de trace nulle, défini par la forme $W \mapsto \text{tr}(W) = \text{tr}(I_m W)$. La direction normale « brute » est donc portée par l'identité I_m .

Cas euclidien. On cherche N avec $\text{tr}(N^{\top} W) = 0$ dès que $\text{tr}(W) = 0$. Cette condition impose $N \propto I_m$, donc $N = I_m$. Avec $\|I_m\|_V^2 = \text{tr}(I_m^{\top} I_m) = m$ et $\langle I_m, X \rangle_V = \text{tr}(X)$:

$$P_{(T_V \mathcal{S}_{m,S}^+)^{\perp}}^{gV}(X) = \frac{\text{tr}(X)}{m} I_m, \quad \text{d'où} \quad P_{T_V \mathcal{S}_{m,S}^+}^{gV}(X) = X - \frac{\text{tr}(X)}{m} I_m.$$

Cas de la métrique de Fisher–Rao. On cherche à nouveau une direction normale naïve corrigée. Le candidat transporté par la métrique associé à la forme $\text{tr}(I_m W)$ est $VI_m V = V^2$, d'où

$$N = V^2 - kV. \quad (13)$$

En imposant $\langle N, W \rangle_V = 0$ pour toute W de trace nulle et en développant (6), la condition devient une équation scalaire linéaire en k , de solution

$$k = \frac{(\alpha - 1) \text{tr}(V)}{2\alpha + (\alpha - 1)m}. \quad (14)$$

La direction normale finale s'écrit alors

$$N = V^2 - \frac{(\alpha - 1) \operatorname{tr}(V)}{2\alpha + (\alpha - 1)m} V, \quad P_{(T_V \mathcal{S}_{m,S}^+)^\perp}^{gV}(X) = \frac{\langle N, X \rangle_V}{\|N\|_V^2} N,$$

la projection sur l'espace tangent étant $X - P_{(T_V \mathcal{S}_{m,S}^+)^\perp}^{gV}(X)$. Comme précédemment, $\|N\|_V^2$ est une constante que l'on calculera au besoin ; la structure de la projection est identique, seule la normale N change.

4.3 Contrainte $S_3(\Sigma) = |\Sigma|^{1/m}$

On rappelle que l'espace tangent s'écrit $T_V \mathcal{S}_{m,S}^+ = \{W \in \mathcal{S}_m \mid \operatorname{tr}(V^{-1}W) = 0\}$, hyperplan défini par la forme $W \mapsto \operatorname{tr}(V^{-1}W)$. La direction normale « brute » est donc portée par V^{-1} .

Cas euclidien. On cherche N avec $\operatorname{tr}(N^\top W) = 0$ dès que $\operatorname{tr}(V^{-1}W) = 0$. Cette condition impose $N \propto V^{-1}$, donc $N = V^{-1}$. Avec $\|V^{-1}\|_V^2 = \operatorname{tr}(V^{-2})$ et $\langle V^{-1}, X \rangle_V = \operatorname{tr}(V^{-1}X)$:

$$P_{(T_V \mathcal{S}_{m,S}^+)^\perp}^{gV}(X) = \frac{\operatorname{tr}(V^{-1}X)}{\operatorname{tr}(V^{-2})} V^{-1}, \quad P_{T_V \mathcal{S}_{m,S}^+}^{gV}(X) = X - \frac{\operatorname{tr}(V^{-1}X)}{\operatorname{tr}(V^{-2})} V^{-1}.$$

Cas de la métrique de Fisher–Rao. On remarque que dans ce cas une normale simple se trouve. En effet, pour toute W telle que $\operatorname{tr}(V^{-1}W) = 0$,

$$\langle V, W \rangle_V = \frac{\alpha}{2} \operatorname{tr}(V^{-1}VV^{-1}W) + \frac{\alpha - 1}{4} \operatorname{tr}(V^{-1}V) \operatorname{tr}(V^{-1}W) = \left(\frac{\alpha}{2} + \frac{(\alpha - 1)m}{4}\right) \underbrace{\operatorname{tr}(V^{-1}W)}_{=0} = 0.$$

Aucune correction n'est nécessaire : $N = V$. Avec $\|V\|_V^2 = \left(\frac{\alpha}{2} + \frac{(\alpha - 1)m}{4}\right)m$ (en utilisant $\operatorname{tr}(V^{-1}V) = m$) et $\langle V, X \rangle_V = \left(\frac{\alpha}{2} + \frac{(\alpha - 1)m}{4}\right) \operatorname{tr}(V^{-1}X)$, la projection se simplifie élégamment :

$$P_{(T_V \mathcal{S}_{m,S}^+)^\perp}^{gV}(X) = \frac{\operatorname{tr}(V^{-1}X)}{m} V, \quad P_{T_V \mathcal{S}_{m,S}^+}^{gV}(X) = X - \frac{\operatorname{tr}(V^{-1}X)}{m} V.$$

4.4 Bilan des projections

$S(\Sigma)$	Normale euclidienne N	Normale Fisher–Rao N
$S_1 = [\Sigma]_{11}$	E_{11}	$VE_{11}V - \frac{\alpha - 1}{\alpha(m + 2) - m} V$
$S_2 = \operatorname{tr}(\Sigma)/m$	I_m	$V^2 - \frac{(\alpha - 1) \operatorname{tr}(V)}{2\alpha + (\alpha - 1)m} V$
$S_3 = \Sigma ^{1/m}$	V^{-1}	V

Dans tous les cas, la projection sur la normale est $P_{(T_V \mathcal{S}_{m,S}^+)^\perp}^{gV}(X) = \frac{\langle N, X \rangle_V}{\|N\|_V^2} N$ et la projection sur l'espace tangent est $X - P_{(T_V \mathcal{S}_{m,S}^+)^\perp}^{gV}(X)$; seule la direction normale N change d'une ligne et d'une colonne à l'autre. On remarque que la contrainte du déterminant est la seule où la correction est nulle (indépendamment de α).

On rappelle enfin que, pour justifier nos décompositions,

$$\mathcal{S}_m = T_V \mathcal{S}_{m,S}^+ \oplus (T_V \mathcal{S}_{m,S}^+)^\perp, \quad (T_V \mathcal{S}_{m,S}^+)^\perp = \operatorname{vect}(N).$$

5 La matrice d'information de Fisher comme espérance de différentielles

Avant d'aborder les calculs, il convient de clarifier la manière dont on écrit la matrice d'information de Fisher (MIF) sur une variété, car ce choix d'écriture conditionne toute la suite.

5.1 Pourquoi éviter la formulation par produit scalaire

Sur une variété riemannienne, le gradient riemannien $\nabla_{\mathcal{M}}\ell$ de la log-vraisemblance ℓ est défini par la relation

$$d\ell(\theta)[h] = \langle \nabla_{\mathcal{M}}\ell(\theta), h \rangle_{\theta}, \quad \forall h \in T_{\theta}\mathcal{M}. \quad (15)$$

On serait tenté de définir la forme d'information de Fisher par $F(u, v) = \mathbb{E}\{\langle \nabla_{\mathcal{M}}\ell, u \rangle_{\theta} \langle \nabla_{\mathcal{M}}\ell, v \rangle_{\theta}\}$. Cette écriture fait cependant intervenir la métrique $\langle \cdot, \cdot \rangle_{\theta}$ deux fois : une première fois pour définir le gradient via (15), une seconde fois dans la formule elle-même. Or le gradient riemannien dépend de la métrique choisie, ce qui n'est pas pratique ; on cherche alors une forme qui, dans un premier temps, ne dépend pas de la métrique.

5.2 La formulation retenue

On revient donc à la différentielle de la log-vraisemblance, objet purement analytique et indépendant de toute métrique. La forme bilinéaire de Fisher s'écrit sans référence explicite au gradient ni à l'inverse de la métrique :

$$F(u, v) \triangleq \mathbb{E}\{d\ell(\theta)[u] d\ell(\theta)[v]\}, \quad [F(\theta)]_{i,j} = F(e_i, e_j), \quad (16)$$

où $\{e_i\}$ est une base de l'espace tangent.

On souligne d'ailleurs que la forme bilinéaire de Fisher définie ci-dessus s'écrit de la même façon pour les deux métriques, ce dont on se servira dans les calculs plus loin : seule la contrainte modifiera le domaine sur lequel on l'évalue.

6 Modèle RES et forme bilinéaire de Fisher

On applique maintenant l'écriture retenue au §5.2 au modèle des lois elliptiquement symétriques réelles. Le résultat, la forme bilinéaire de Fisher, est construit sur $\mathcal{S}_m$ tout entier et indépendamment de toute contrainte comme de toute métrique : on rappelle d'abord le modèle, puis on en dérive le score avant d'assembler la forme.

6.1 Lois RES : densité et représentation stochastique

Le calcul de la forme de Fisher repose de manière essentielle sur la densité et sur la représentation stochastique des lois elliptiquement symétriques réelles.

Densité. Lorsqu'elle existe, la densité d'une variable $\mathbf{x} \sim \text{RES}_m(\boldsymbol{\mu}, \Sigma, g)$ s'écrit

$$p(\mathbf{x} \mid \boldsymbol{\mu}, \Sigma, g) = |\Sigma|^{-1/2} g((\mathbf{x} - \boldsymbol{\mu})^{\top} \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})), \quad (17)$$

où $g : \mathbb{R}^+ \rightarrow \mathbb{R}^+$ est le générateur de densité, supposé tel que $\int_0^{+\infty} t^{m/2-1} g(t) dt < +\infty$ (la constante de normalisation étant absorbée dans g). C'est bien (17) qui, à $\boldsymbol{\mu} = 0$ et $\Sigma = V$, fournit la log-vraisemblance utilisée au §6.2 : le terme $-\frac{1}{2} \ln |V|$ provient du facteur $|\Sigma|^{-1/2}$, et le terme $\ln g(t)$ du générateur évalué en $t = \mathbf{x}^{\top} V^{-1} \mathbf{x}$.

Représentation stochastique. D'après [3], éq. (11), une variable $\mathbf{x} \sim \text{RES}_m(\boldsymbol{\mu}, \Sigma, g)$ admet la représentation

$$\mathbf{x} \stackrel{d}{=} \boldsymbol{\mu} + \sqrt{Q} \Sigma^{1/2} \mathbf{s}, \quad (18)$$

où $\mathbf{s}$ est uniforme sur la sphère unité S^{m-1} de $\mathbb{R}^m$, la variable modulaire $Q = \mathbf{x}^\top \Sigma^{-1} \mathbf{x}$ (le « rayon au carré ») lui est indépendante, et $\Sigma^{1/2}$ est une racine carrée de Σ . Dans notre contexte on travaille à moyenne nulle $\boldsymbol{\mu} = 0$ et avec la matrice de forme V , de sorte que $\mathbf{x} \stackrel{d}{=} \sqrt{t} V^{1/2} \mathbf{s}$ avec $t = \mathbf{x}^\top V^{-1} \mathbf{x}$.

6.2 Différentielle du score

Pour $\mathbf{x} \sim \text{RES}_m(0, V, g)$, la log-vraisemblance d'une observation est

$$\ell(V) = -\frac{1}{2} \ln |V| + \ln g(t), \quad t = \mathbf{x}^\top V^{-1} \mathbf{x}.$$

On calcule sa différentielle dans la direction $u \in \mathcal{S}_m$, terme par terme.

Terme du déterminant. L'identité $d \ln |V| [u] = \text{tr}(V^{-1} u)$ donne

$$d\left(-\frac{1}{2} \ln |V|\right)[u] = -\frac{1}{2} \text{tr}(V^{-1} u).$$

Terme du générateur. Par la règle de la chaîne, $d \ln g(t) [u] = \frac{g'(t)}{g(t)} dt [u]$. La différentielle de $t = \mathbf{x}^\top V^{-1} \mathbf{x}$ utilise celle de l'inverse, obtenue en dérivant $V V^{-1} = I_m$:

$$d(V^{-1})[u] = -V^{-1} u V^{-1} \implies dt[u] = -\mathbf{x}^\top V^{-1} u V^{-1} \mathbf{x}. \quad (19)$$

En introduisant $\psi(t) \triangleq -2g'(t)/g(t)$, soit $g'(t)/g(t) = -\frac{1}{2}\psi(t)$, les deux signes se combinent :

$$d \ln g(t) [u] = \frac{1}{2} \psi(t) \mathbf{x}^\top V^{-1} u V^{-1} \mathbf{x}.$$

Au total,

$$d\ell(V)[u] = -\frac{1}{2} \text{tr}(V^{-1} u) + \frac{1}{2} \psi(t) \mathbf{x}^\top V^{-1} u V^{-1} \mathbf{x}. \quad (20)$$

L'astuce de la trace $\mathbf{x}^\top B \mathbf{x} = \text{tr}(B \mathbf{x} \mathbf{x}^\top)$ permet d'isoler $\mathbf{x} \mathbf{x}^\top$, sur lequel on prendra l'espérance.

6.3 Le score est centré

Une propriété clé simplifie tout le calcul : $\mathbb{E}\{d\ell(V)[u]\} = 0$. Elle vient de ce que la densité s'intègre à 1 pour tout V :

$$\int p(\mathbf{x} | V) d\mathbf{x} = 1 \quad \forall V \implies \int dp(\mathbf{x} | V)[u] d\mathbf{x} = 0.$$

En écrivant $dp[u] = p \cdot d\ell[u]$, l'intégrale devient une espérance, d'où $\mathbb{E}\{d\ell(V)[u]\} = 0$.

Reste à en déduire l'identité (21). On injecte l'expression du score et on prend l'espérance des deux termes. En utilisant l'astuce de la trace $\mathbf{x}^\top V^{-1} u V^{-1} \mathbf{x} = \text{tr}(V^{-1} u V^{-1} \mathbf{x} \mathbf{x}^\top)$ et la linéarité de l'espérance :

$$0 = \mathbb{E}\{d\ell(V)[u]\} = -\frac{1}{2} \text{tr}(V^{-1} u) + \frac{1}{2} \text{tr}\left(V^{-1} u V^{-1} \mathbb{E}\{\psi(t) \mathbf{x} \mathbf{x}^\top\}\right).$$

En multipliant par 2 et en regroupant, on obtient, pour toute direction $u \in \mathcal{S}_m$,

$$\text{tr}\left(V^{-1} u V^{-1} (\mathbb{E}\{\psi(t) \mathbf{x} \mathbf{x}^\top\} - V)\right) = 0,$$

puisque $\text{tr}(V^{-1} u) = \text{tr}(V^{-1} u V^{-1} V)$. Comme u est arbitraire et que la forme $u \mapsto \text{tr}(V^{-1} u V^{-1} M)$ ne peut être identiquement nulle que si $M = 0$, on conclut $\mathbb{E}\{\psi(t) \mathbf{x} \mathbf{x}^\top\} - V = 0$, soit

$$\mathbb{E}\{\psi(t) \mathbf{x} \mathbf{x}^\top\} = V. \quad (21)$$

C'est cette identité qui fera disparaître les termes croisés de la forme de Fisher.

6.4 La forme bilinéaire de Fisher

On assemble $F(u, v) = \mathbb{E}\{d\ell[u] d\ell[v]\}$. En posant $A = V^{-1}vV^{-1}$ et $B = V^{-1}uV^{-1}$, le développement donne trois contributions.

Terme déterministe. $\frac{1}{4} \text{tr}(V^{-1}u) \text{tr}(V^{-1}v)$.

Termes croisés. Par (21), $\mathbb{E}\{\psi(t)\mathbf{x}^\top B\mathbf{x}\} = \text{tr}(BV) = \text{tr}(V^{-1}u)$, si bien que les deux termes croisés se somment en $-\frac{1}{2} \text{tr}(V^{-1}u) \text{tr}(V^{-1}v)$.

Terme d'ordre 4. C'est $T_3 = \frac{1}{4} \mathbb{E}\{\psi(t)^2(\mathbf{x}^\top B\mathbf{x})(\mathbf{x}^\top A\mathbf{x})\}$, un moment d'ordre 4 en $\mathbf{x}$ pondéré par $\psi(t)^2$. C'est le calcul le plus long ; on le détaille pas à pas.

Étape 1 — substitution de la représentation stochastique. On injecte $\mathbf{x} \stackrel{d}{=} \sqrt{t}V^{1/2}\mathbf{s}$ (éq. (18)) dans chaque facteur quadratique. En posant $\tilde{A} \triangleq V^{1/2}AV^{1/2}$ et $\tilde{B} \triangleq V^{1/2}BV^{1/2}$,

$$\mathbf{x}^\top B\mathbf{x} = t \mathbf{s}^\top \tilde{B}\mathbf{s}, \quad \mathbf{x}^\top A\mathbf{x} = t \mathbf{s}^\top \tilde{A}\mathbf{s},$$

d'où $\psi(t)^2(\mathbf{x}^\top B\mathbf{x})(\mathbf{x}^\top A\mathbf{x}) = t^2\psi(t)^2(\mathbf{s}^\top \tilde{B}\mathbf{s})(\mathbf{s}^\top \tilde{A}\mathbf{s})$.

Étape 2 — factorisation par indépendance. Comme t et $\mathbf{s}$ sont indépendants (éq. (18)), l'espérance du produit se factorise :

$$\mathbb{E}\{\psi(t)^2(\mathbf{x}^\top B\mathbf{x})(\mathbf{x}^\top A\mathbf{x})\} = \mathbb{E}\{t^2\psi(t)^2\} \mathbb{E}\{(\mathbf{s}^\top \tilde{B}\mathbf{s})(\mathbf{s}^\top \tilde{A}\mathbf{s})\}.$$

Étape 3 — passage en indices. On développe les deux formes quadratiques, $\mathbf{s}^\top \tilde{B}\mathbf{s} = \sum_{i,j} \tilde{B}_{ij}s_is_j$ et $\mathbf{s}^\top \tilde{A}\mathbf{s} = \sum_{k,\ell} \tilde{A}_{k\ell}s_ks_\ell$, ce qui ramène le calcul au moment d'ordre 4 des coordonnées de $\mathbf{s}$:

$$\mathbb{E}\{(\mathbf{s}^\top \tilde{B}\mathbf{s})(\mathbf{s}^\top \tilde{A}\mathbf{s})\} = \sum_{i,j,k,\ell} \tilde{B}_{ij}\tilde{A}_{k\ell} \mathbb{E}\{s_is_js_ks_\ell\}, \quad \mathbb{E}\{s_is_js_ks_\ell\} = \frac{\delta_{ij}\delta_{k\ell} + \delta_{ik}\delta_{j\ell} + \delta_{i\ell}\delta_{jk}}{m(m+2)}.$$

Étape 4 — contraction des trois termes. On traite chaque produit de deltas séparément, en utilisant la symétrie de $\tilde{A}$ et $\tilde{B}$:

- $\delta_{ij}\delta_{k\ell}$ impose $i = j, k = \ell$: $\sum_i \tilde{B}_{ii} \sum_k \tilde{A}_{kk} = \text{tr}(\tilde{B}) \text{tr}(\tilde{A})$;
- $\delta_{ik}\delta_{j\ell}$ impose $i = k, j = \ell$: $\sum_{i,j} \tilde{B}_{ij} \tilde{A}_{ij} = \text{tr}(\tilde{A}\tilde{B})$;
- $\delta_{i\ell}\delta_{jk}$ impose $i = \ell, j = k$: $\sum_{i,j} \tilde{B}_{ij} \tilde{A}_{ji} = \text{tr}(\tilde{A}\tilde{B})$ (identique au précédent).

Les deux derniers fusionnent en un facteur 2 :

$$\mathbb{E}\{(\mathbf{s}^\top \tilde{B}\mathbf{s})(\mathbf{s}^\top \tilde{A}\mathbf{s})\} = \frac{\text{tr}(\tilde{A}) \text{tr}(\tilde{B}) + 2 \text{tr}(\tilde{A}\tilde{B})}{m(m+2)}.$$

Étape 5 — retour aux variables u, v . On élimine les $V^{1/2}$:

$$\text{tr}(\tilde{A}) = \text{tr}(AV) = \text{tr}(V^{-1}v), \quad \text{tr}(\tilde{B}) = \text{tr}(V^{-1}u), \quad \text{tr}(\tilde{A}\tilde{B}) = \text{tr}(AVBV) = \text{tr}(V^{-1}uV^{-1}v).$$

Étape 6 — coefficient de Fisher et conclusion. En posant

$$\alpha_g \triangleq \frac{\mathbb{E}\{t^2\psi(t)^2\}}{m(m+2)} \tag{22}$$

(qui concentre toute la dépendance en la loi g), le terme d'ordre 4 vaut, en distribuant le $\frac{1}{4}$,

$$T_3 = \frac{\alpha_g}{4} \left(\text{tr}(V^{-1}u) \text{tr}(V^{-1}v) + 2 \text{tr}(V^{-1}uV^{-1}v) \right) = \frac{\alpha_g}{2} \text{tr}(V^{-1}uV^{-1}v) + \frac{\alpha_g}{4} \text{tr}(V^{-1}u) \text{tr}(V^{-1}v).$$

Assemblage. En sommant les trois contributions, le coefficient du terme en produit de traces devient $\frac{1}{4} - \frac{1}{2} + \frac{\alpha_g}{4} = \frac{\alpha_g - 1}{4}$, et l'on obtient la forme bilinéaire de Fisher :

$$F(u, v) = \frac{\alpha_g}{2} \operatorname{tr}(V^{-1}u V^{-1}v) + \frac{\alpha_g - 1}{4} \operatorname{tr}(V^{-1}u) \operatorname{tr}(V^{-1}v).$$

On retrouve *a posteriori* la forme du produit scalaire de Fisher–Rao (6) avec $\alpha = \alpha_g$, mais on ne l'a jamais supposée : elle sort du calcul.

6.5 Validité sur $\mathcal{S}_m$ tout entier

Le calcul qui précède n'a utilisé aucune contrainte : ni la caractérisation (3) de l'espace tangent, ni le choix d'une fonction d'échelle S n'y interviennent. La forme obtenue

$$F(u, v) = \frac{\alpha_g}{2} \operatorname{tr}(V^{-1}u V^{-1}v) + \frac{\alpha_g - 1}{4} \operatorname{tr}(V^{-1}u) \operatorname{tr}(V^{-1}v), \quad u, v \in \mathcal{S}_m, \quad (23)$$

est donc valable sur $\mathcal{S}_m$ tout entier, sans aucune restriction.

Remarque 6.1. Passer de $\mathcal{S}_m$ à la sous-variété ne demandera aucun nouveau calcul : on lira (23) sur une base de $T_V \mathcal{S}_{m,S}^+$ au lieu d'une base de $\mathcal{S}_m$. Pour la contrainte S_1 , par exemple, on évaluera F sur la base $\{e_{ij}\}_{(i,j) \neq (1,1)}$ de $T_V \mathcal{S}_{m,S}^+$, qui exclut la direction de coefficient $(1, 1)$, au lieu de la base complète de $\mathcal{S}_m$ (voir §7.2). On passe donc d'une base à $d = \frac{m(m+1)}{2}$ vecteurs à une base à $p = \frac{m(m+1)}{2} - 1$ vecteurs : une seule dimension de moins, celle associée à E_{11} . Le premier coefficient n'est plus évalué, tout le reste est identique.

7 Bases orthonormées et assemblage de $P_{\mathcal{E}}(V)$ et $F(V)$

On dispose désormais des deux ingrédients : la forme bilinéaire de Fisher sur $\mathcal{S}_m$ (section 6) et la description des espaces tangents (sections 3 et 4). Il reste à les combiner pour construire la matrice de projection $P_{\mathcal{E}}(V)$, définie par l'équation (15) de [2], et la matrice d'information de Fisher $F(V)$ sur la sous-variété de forme. On énonce d'abord la procédure générale, puis on la déroule sur les deux premières contraintes.

7.1 Procédure générale de calcul

La procédure de calcul de la matrice d'information de Fisher et des matrices de projection $P_{\mathcal{E}}(V)$ se résume ainsi.

1. **Forme bilinéaire de Fisher.** On calcule $F(u, v) = \mathbb{E}\{\mathrm{d}\ell(\theta)[u]\mathrm{d}\ell(\theta)[v]\}$. Elle ne dépend ni de la contrainte ni de la métrique : c'est le résultat encadré du §6.4, valable sur $\mathcal{S}_m$ tout entier. Seule change, au point suivant, la base sur laquelle on l'évalue.
2. **Base orthonormée par Gram–Schmidt.** À partir de la base de chaque espace tangent obtenue à la section 3, on construit une base orthonormée relativement à une métrique g (euclidienne ou Fisher–Rao) par le procédé d'orthonormalisation de Gram–Schmidt. On peut ensuite évaluer la matrice de Fisher et les $P_{\mathcal{E}}(V)$ associées.

Remarque 7.1. Pour le point 2, il n'est pas nécessaire de procéder explicitement, c'est-à-dire de voir écrite la forme de la matrice de Fisher. Il suffit de la calculer numériquement. Une fois que l'on dispose de la forme bilinéaire de Fisher et des trois bases des trois espaces tangents explicites, le point 2 peut être entièrement réalisé sur ordinateur : orthonormalisation, assemblage de $F(V)$ et de $P_{\mathcal{E}}(V)$.

Relation utilisée. Plutôt que de passer par une écriture matricielle, il est plus simple d'exprimer directement la restriction au niveau de la forme bilinéaire. La forme de Fisher F est définie sur $\mathcal{S}_m$ tout entier, et la forme restreinte à la sous-variété n'est que la restriction de ses arguments :

$$F|_{T_V \mathcal{S}_{m,S}^+}(u, v) = F(u, v), \quad u, v \in T_V \mathcal{S}_{m,S}^+ \subset \mathcal{S}_m.$$

Autrement dit, on ne change rien à F : on se contente de ne l'évaluer que sur des directions tangentes. La contrainte n'intervient donc pas dans le calcul de la forme, mais uniquement dans le domaine sur lequel on l'évalue.

Une fois qu'on dispose d'une base $\{\bar{e}_i\}_{i=1}^p$ de $T_V \mathcal{S}_{m,S}^+$ (orthonormée pour la métrique choisie, obtenue par Gram-Schmidt), la matrice d'information de Fisher s'obtient simplement en évaluant la forme sur les paires de vecteurs de cette base :

$$[F(V)]_{i,j} = F(\bar{e}_i, \bar{e}_j), \quad i, j = 1, \dots, p. \quad (24)$$

C'est la relation que l'on utilisera. Elle présente l'avantage d'être uniforme pour les trois contraintes : seule la base $\{\bar{e}_i\}$ change d'une contrainte à l'autre (et d'une métrique à l'autre), tandis que la forme bilinéaire F reste la même puisqu'elle ne dépend ni de la contrainte ni de la métrique. Le calcul se réduit donc à : produire la base tangente, l'orthonormaliser, puis évaluer F sur ses paires, le tout numériquement.

7.2 Contrainte $\mathcal{S}_1$: les deux bases et $P_{\mathcal{E}}(V)$

Les deux bases nécessaires s'obtiennent simplement. La base de l'espace tangent complet $\mathcal{S}_m$ est la base canonique $\{L_{ij}\}_{1 \leq i \leq j \leq m}$ des matrices symétriques. La base de l'espace restreint $T_V \mathcal{S}_{m,S}^+$ est tout aussi immédiate pour cette contrainte : c'est celle des matrices symétriques privée de l'élément de coefficient $(1, 1)$, c'est-à-dire $\{L_{ij}\}_{(i,j) \neq (1,1)}$, puisque la contrainte $[W]_{11} = 0$ ne fait qu'exclure la direction E_{11} .

Remarque 7.2. On aurait pu retrouver ce résultat par la construction générale via les matrices K, M, D de la section 3. Mais ce n'est pas nécessaire ici : le gradient $\nabla_{\widetilde{\text{vecs}(V)}}[V]_{11} = 0$ pour cette contrainte, si bien que la base se réduit directement aux matrices symétriques canoniques sans E_{11} .

En travaillant dans la base orthonormée $e_{ij} = L_{ij}/\|L_{ij}\|$ de $T_V \mathcal{S}_{m,S}^+$ (avec $\|L_{ii}\| = 1$ et $\|L_{ij}\| = \sqrt{2}$ pour $i < j$), la matrice E_{θ} telle que

$$[E_{\theta}]_{i,j} = \langle \tilde{e}_i, e_j \rangle_V, \quad i = 1, \dots, p, \quad j = 1, \dots, d, \quad (25)$$

où $\{\tilde{e}_i\}_{i=1}^p$ est la base orthonormée de $T_V \mathcal{S}_{m,S}^+$ et $\{e_j\}_{j=1}^d$ celle de $\mathcal{S}_m$, possède une unique entrée non nulle par ligne, égale à 1 ; la matrice de projection $P_{\mathcal{E}}(V) = E_{\theta}^{\top} E_{\theta}$ est alors le projecteur orthogonal (idempotent) sur $T_V \mathcal{S}_{m,S}^+$:

$$P_{\mathcal{E}}(V) = \text{diag}(0, 1, 1, \dots, 1),$$

avec un 0 sur la composante $(1, 1)$ figée par la contrainte et des 1 sur les p composantes libres. Son action reproduit la projection obtenue au §4.1 : $X \mapsto X - X_{11} E_{11}$.

Remarque 7.3. Au niveau de la représentation matricielle, la base orthonormée de l'espace restreint $T_V \mathcal{S}_{m,S}^+$ n'est autre que la base orthonormée de $\mathcal{S}_m$ décalée d'un cran : $\tilde{e}_i = e_{i+1}$, $i = 1, \dots, p$. Autrement dit, on retire simplement le premier vecteur e_1 et on ré-indexe les suivants. C'est exactement ce que traduit la matrice $E_{\theta} = (0 \mid I_p)$, d'où $P_{\mathcal{E}}(V) = \text{diag}(0, 1, \dots, 1)$.

7.3 Contrainte S_1 : calcul numérique de $P_{\mathcal{E}}(V)$ pour la métrique de Fisher–Rao

Pour la métrique euclidienne, la base tangente était déjà orthonormée (à normalisation près) et $P_{\mathcal{E}}(V)$ se réduisait à la diagonale $\text{diag}(0, 1, \dots, 1)$. Pour la métrique de Fisher–Rao, la démarche est identique dans son principe, mais l’orthonormalisation n’est plus triviale : elle doit se faire relativement au produit scalaire de Fisher–Rao, ce qui fait intervenir V^{-1} . On procède donc en quatre temps.

1. **La base tangente est la même.** La base de $T_V \mathcal{S}_{m,S}^+$ ne dépend pas de la métrique : c’est toujours celle des matrices symétriques canoniques privée de E_{11} ,

$$\{\Xi_i\}_{i=1}^p = \{L_{k\ell}\}_{(k,\ell) \neq (1,1)}, \quad p = \frac{m(m+1)}{2} - 1.$$

2. **Orthonormalisation par Gram–Schmidt pour la métrique de Fisher–Rao.** Contrairement au cas euclidien, les Ξ_i ne sont ni normés ni orthogonaux pour $\langle \cdot, \cdot \rangle_V$. On construit donc une base $\{f_i\}_{i=1}^p$ orthonormée au sens de Fisher–Rao par le procédé de Gram–Schmidt,

$$f_k = \frac{1}{\|\tilde{f}_k\|_V} \left(\Xi_k - \sum_{j < k} \langle \Xi_k, f_j \rangle_V f_j \right), \quad \|A\|_V = \sqrt{\langle A, A \rangle_V},$$

où tous les produits scalaires sont ceux de Fisher–Rao,

$$\langle A, B \rangle_V = \frac{\alpha}{2} \text{tr}(V^{-1} A V^{-1} B) + \frac{\alpha - 1}{4} \text{tr}(V^{-1} A) \text{tr}(V^{-1} B).$$

C’est à cette étape que V^{-1} entre dans les coefficients : les projections successives du Gram–Schmidt dépendent de V , alors qu’en euclidien elles étaient de simples 0 et 1.

3. **Une base orthonormée de $\mathcal{S}_m$ pour la même métrique.** La matrice E_{θ} recueille, ligne par ligne, les coordonnées des f_i dans une base de l’espace tangent complet $\mathcal{S}_m$. Pour que ces coordonnées se lisent simplement comme des produits scalaires $\langle f_i, \cdot \rangle_V$, et donc pour que $E_{\theta}^{\top} E_{\theta}$ soit idempotente, la base de $\mathcal{S}_m$ employée en colonnes doit elle aussi être orthonormée pour $\langle \cdot, \cdot \rangle_V$. Or la base canonique $\{L_j\}_{j=1}^d$ ne l’est que pour la métrique euclidienne (à normalisation près) ; pour Fisher–Rao, ses éléments sont couplés par V^{-1} exactement comme les Ξ_i de l’étape 2. On lui applique donc le même procédé de Gram–Schmidt, ce qui fournit

$$\{u_j\}_{j=1}^d \text{ orthonormée pour } \langle \cdot, \cdot \rangle_V, \quad \langle u_j, u_{j'} \rangle_V = \delta_{jj'}.$$

4. **Assemblage via les équations (14)–(15) de [2].** Une fois les deux bases orthonormées $\{f_i\}$ et $\{u_j\}$ obtenues, on applique les définitions de [2] telles quelles. On forme la matrice E_{θ} de taille $p \times d$ par

$$[E_{\theta}]_{i,j} = \langle f_i, u_j \rangle_V, \quad i = 1, \dots, p, \quad j = 1, \dots, d,$$

puis la matrice de projection

$$P_{\mathcal{E}}(V) = E_{\theta}^{\top} E_{\theta} = (\langle f_i, u_j \rangle_V)^{\top} (\langle f_i, u_j \rangle_V).$$

Comme les deux bases $\{f_i\}$ et $\{u_j\}$ sont orthonormées pour la même métrique, E_{θ} est bien la matrice des coordonnées de la base tangente, et $P_{\mathcal{E}}(V)$ est un projecteur idempotent de rang p . Ses entrées dépendent de V^{-1} : ce n’est plus la diagonale $\text{diag}(0, 1, \dots, 1)$ du cas euclidien.

Remarque 7.4. En euclidien, $u_j = L_j / \|L_j\|$ convient directement, le Gram–Schmidt sur $\mathcal{S}_m$ est trivial et l’on retrouve $E_{\theta} = (0 \mid I_p)$, donc $P_{\mathcal{E}}(V) = \text{diag}(0, 1, \dots, 1)$ comme au §7.2. En Fisher–Rao, sauter cette étape et utiliser directement $\{L_j\}$ produirait une matrice $E_{\theta}^{\top} E_{\theta}$ qui n’est plus idempotente : ce ne serait pas un projecteur.

Remarque 7.5. Comme précisé plus haut pour la matrice de Fisher, on n’a pas besoin d’écrire la forme explicite de $P_{\mathcal{E}}(V)$. Une fois la base tangente $\{\Xi_i\}$ posée explicitement, les quatre temps ci-dessus, Gram–Schmidt sur $T_V \mathcal{S}_{m,S}^+$ puis sur $\mathcal{S}_m$ pour la métrique de Fisher–Rao, calcul des produits scalaires $\langle f_i, u_j \rangle_V$, et produit $E_\theta^\top E_\theta$ se réalisent entièrement sur ordinateur. Il suffit d’implémenter le produit scalaire de Fisher–Rao (deux traces) et le procédé de Gram–Schmidt ; l’assemblage de $P_{\mathcal{E}}(V)$ en découle. La même procédure vaut pour les deux autres contraintes, en changeant seulement la base tangente de départ.

7.4 Contrainte S_2 : gradient de la contrainte et base tangente

On traite maintenant la contrainte de la trace, $S_2(\Sigma) = \text{tr}(\Sigma)/m$, pour laquelle l’espace tangent est $T_V \mathcal{S}_{m,S}^+ = \{W \in \mathcal{S}_m \mid \text{tr}(W) = 0\}$. La démarche est en tout point parallèle à celle de la première contrainte.

Le document [2] fournit le gradient de $[V]_{11}$ par rapport aux entrées libres $\widetilde{\text{vecs}}(V)$:

$$\nabla_{\widetilde{\text{vecs}}(V)}^\top [V]_{11} = - - \frac{\text{vec}(I_m)^\top D_m I_m^\top}{(\text{vec}(I_m)^\top D_m)_1}.$$

où l’on a utilisé que $\text{vec}(I_m)^\top D_m \text{vecs}(A) = \text{tr}(A)$, de sorte que le vecteur ligne $\text{vec}(I_m)^\top D_m$ vaut 1 aux positions diagonales et 0 ailleurs. Ce vecteur mesure la variation de l’entrée contrainte $[V]_{11}$ lorsqu’on fait bouger chacune des entrées libres. La contrainte $\text{tr}(V) = m$ s’écrit $\sum_i [V]_{ii} = m$, soit

$$[V]_{11} = m - \sum_{i=2}^m [V]_{ii}.$$

En dérivant par rapport à une entrée libre $[V]_{k\ell}$ (avec $(k, \ell) \neq (1, 1)$), on obtient

$$\frac{\partial [V]_{11}}{\partial [V]_{k\ell}} = \begin{cases} -1 & \text{si } k = \ell \quad (\text{entrée diagonale, } k \geq 2), \\ 0 & \text{si } k < \ell \quad (\text{entrée hors-diagonale}). \end{cases}$$

Autrement dit, augmenter une entrée diagonale libre $[V]_{ii}$ oblige $[V]_{11}$ à diminuer d’autant (pour conserver la trace), tandis que les entrées hors-diagonale n’affectent pas la trace, donc pas $[V]_{11}$. C’est exactement ce qu’encode la formule ci-dessus : $\text{vec}(I_m)$ sélectionne les positions diagonales et le signe -1 traduit la compensation.

Base tangente. En traduisant la matrice $K_S^V = (\nabla_{\widetilde{\text{vecs}}(V)}^\top [V]_{11} ; I_p)^\top$ via $M_S^V = (K_S^V)^\top D_m^\top$, chaque vecteur de base Ξ_j se lit directement :

- entrée hors-diagonale (k, ℓ) , $k < \ell$: le gradient vaut 0, donc $\Xi_j = E_{k\ell} + E_{\ell k}$ (trace nulle) ;
- entrée diagonale (i, i) , $i \geq 2$: le gradient vaut -1 en position $(1, 1)$, donc $\Xi_j = E_{ii} - E_{11}$ (trace nulle).

On retrouve bien $T_V \mathcal{S}_{m,S}^+ = \{W \mid \text{tr}(W) = 0\}$: la base est

$$\mathcal{E}_V = \{E_{ii} - E_{11}\}_{i=2}^m \cup \{E_{k\ell} + E_{\ell k}\}_{k < \ell}, \quad p = \frac{m(m+1)}{2} - 1.$$

7.5 Contrainte S_2 : produits scalaires euclidiens et orthogonalité

Avec la métrique euclidienne $\langle A, B \rangle_V = \text{tr}(AB)$, on calcule les produits scalaires entre vecteurs de base. Les directions hors-diagonale sont orthogonales entre elles et orthogonales aux diagonales, de norme $\sqrt{2}$. En revanche, les directions diagonales ne sont pas orthogonales entre elles : pour $i, j \geq 2$,

$$\langle E_{ii} - E_{11}, E_{jj} - E_{11} \rangle_V = \text{tr}((E_{ii} - E_{11})(E_{jj} - E_{11})) = \delta_{ij} + 1 = \begin{cases} 2 & i = j, \\ 1 & i \neq j, \end{cases}$$

le terme commun E_{11} créant un couplage. Ces $m - 1$ directions engendrent le sous-espace des matrices diagonales de trace nulle, c’est-à-dire l’orthogonal de I_m parmi les matrices diagonales.

7.6 Contrainte S_2 : la matrice de projection

Plutôt que d'expliciter le Gram–Schmidt sur les directions diagonales, on utilise la direction normale déjà obtenue au §4.2 (cas euclidien) : $N = I_m$, puisque $T_V \mathcal{S}_{m,S}^+ = \{W \mid \langle I_m, W \rangle_V = 0\}$. Le projecteur orthogonal sur $T_V \mathcal{S}_{m,S}^+$ retranche la composante selon I_m ,

$$X \mapsto X - \frac{\langle I_m, X \rangle_V}{\|I_m\|^2} I_m = X - \frac{\text{tr}(X)}{m} I_m, \quad \|I_m\|^2 = \text{tr}(I_m) = m.$$

En représentation $\text{vecs}(\cdot)$, en notant $\mathbf{s} = \text{vecs}(I_m)$ le vecteur qui repère les positions diagonales (avec $\|\mathbf{s}\|^2 = m$), la matrice de projection est

$$P_{\mathcal{E}}(V) = I_d - \frac{1}{m} \mathbf{s} \mathbf{s}^\top, \quad \mathbf{s} = \text{vecs}(I_m).$$

On vérifie qu'il s'agit bien d'un projecteur de rang $p = d - 1$:

$$P_{\mathcal{E}}(V)^2 = I_d - \frac{2}{m} \mathbf{s} \mathbf{s}^\top + \frac{1}{m^2} \underbrace{\mathbf{s} (\mathbf{s}^\top \mathbf{s})}_{=m} \mathbf{s}^\top = I_d - \frac{1}{m} \mathbf{s} \mathbf{s}^\top = P_{\mathcal{E}}(V),$$

et son action sur $\text{vecs}(X)$ redonne $\text{vecs}(X - \frac{\text{tr}(X)}{m} I_m)$.

Comme précisé plus haut, la matrice de projection avec l'autre métrique ou la matrice de Fisher s'obtiennent numériquement grâce à la formule du §7.1 ou par Gram–Schmidt. On aurait bien entendu pu faire Gram–Schmidt directement en euclidien, mais il était intéressant de voir comment utiliser le projecteur obtenu plus haut (expression de la normale simple) ; le résultat est le même.

Remarque 7.6. La troisième contrainte, $S_3(\Sigma) = |\Sigma|^{1/m}$, ne fait l'objet d'aucune sous-section propre : la démarche est en tout point celle de la contrainte de la trace, seule la base tangente de départ changeant. Sa direction normale a été obtenue au §4.3 et la procédure du §7.1 s'y applique telle quelle.

Remarque 7.7. On peut utiliser ces projections dans le théorème 2, éq. (8) de [6], ce qui ne changerait pas le résultat pour la partie numérique, mais nous allons proposer un autre raisonnement. L'idée est maintenant de valider numériquement les résultats théoriques par des simulations de Monte-Carlo.

8 Approximation du logarithme riemannien

8.1 Pourquoi approximer le logarithme riemannien

On cherche maintenant à valider numériquement la borne de Cramér–Rao intrinsèque grâce aux outils calculés. Il faut pour cela mesurer la dispersion de l'estimateur $\hat{\theta}$ autour de la vraie valeur θ_0 (dans notre application, $\theta = V$ et $\hat{\theta} = \hat{V}_n$). Sur une variété, l'écart entre deux points ne se mesure pas par une simple soustraction : c'est le logarithme riemannien $\text{Log}_{\theta_0}(\hat{\theta})$ qui joue ce rôle. Il fournit le vecteur tangent en θ_0 pointant vers $\hat{\theta}$, et c'est lui qui entre dans la définition de la matrice de covariance de l'estimateur :

$$[C(\hat{\theta}, \theta_0)]_{i,j} \triangleq \mathbb{E} \left\{ \langle \text{Log}_{\theta_0}(\hat{\theta}), \bar{e}_i \rangle_{\theta_0} \langle \text{Log}_{\theta_0}(\hat{\theta}), \bar{e}_j \rangle_{\theta_0} \right\}, \quad (26)$$

où $\{\bar{e}_i\}$ est une base orthonormée de $T_{\theta_0} \mathcal{S}_{m,S}^+$. La borne de Cramér–Rao à valider s'écrit alors

$$C(\hat{\theta}, \theta_0) \succeq F(\theta_0)^{-1} + \text{termes de courbure}, \quad (27)$$

F étant la matrice d'information de Fisher construite plus haut.

Le logarithme riemannien n'ayant pas de forme close sur $\mathcal{S}_{m,S}^+$, on l'approche par la projection sur l'espace tangent $T_{\theta_0}\mathcal{S}_{m,S}^+$ de l'écart $\hat{\theta} - \theta_0$:

$$\text{Log}_{\theta_0}(\hat{\theta}) \simeq P_{T_{\theta_0}}(\hat{\theta} - \theta_0). \quad (28)$$

Cette projection dépend cependant du produit scalaire choisi (euclidien ou Fisher–Rao), donc de la base orthonormée utilisée — dont le dernier vecteur e_d diffère d'une métrique à l'autre. Le logarithme riemannien, lui, est unique et intrinsèque : il ne dépend d'aucun choix de base.

Il faut donc vérifier deux choses : d'une part que cette projection approche effectivement le logarithme riemannien, d'autre part que l'ambiguïté introduite par le choix du projecteur n'affecte l'approximation qu'à un ordre négligeable, ce qui garantira que la borne validée numériquement ne dépend pas de ce choix.

8.2 La projection approche le logarithme riemannien

On établit d'abord le premier point, pour une métrique quelconque.

Proposition 8.1 (Cohérence de l'approximation du logarithme). *Soit g une métrique riemannienne sur $\mathcal{S}_{m,S}^+$ et $P_{T_{\theta_0}}^g$ une projection qui laisse l'espace tangent invariant sur $T_{\theta_0}\mathcal{S}_{m,S}^+$. On admet que Log_{θ_0} est bien défini et lisse sur un voisinage de θ_0 , avec $D\exp_{\theta_0}(0) = \text{id}_{T_{\theta_0}\mathcal{S}_{m,S}^+}$ (voir par exemple [7] et [10]). Alors, pour tout θ assez proche de θ_0 ,*

$$\text{Log}_{\theta_0}(\theta) = P_{T_{\theta_0}}^g(\theta - \theta_0) + O(\|\theta - \theta_0\|^2).$$

Démonstration. (i) *Développement de l'exponentielle.* Posons $\rho(v) = \exp_{\theta_0}(v) - \theta_0 - v$ pour $v \in T_{\theta_0}\mathcal{S}_{m,S}^+$. On a $\rho(0) = 0$ et, par hypothèse, $D\rho(0) = D\exp_{\theta_0}(0) - \text{id} = 0$; par Taylor à l'ordre deux,

$$\exp_{\theta_0}(v) = \theta_0 + v + \rho(v), \quad \|\rho(v)\| \leq C_1\|v\|^2. \quad (29)$$

(ii) *Inversion et équivalence des normes.* Le logarithme étant bien défini au voisinage de θ_0 (hypothèse), il existe un unique $v \in T_{\theta_0}\mathcal{S}_{m,S}^+$ tel que $\theta = \exp_{\theta_0}(v)$; on pose $v := \text{Log}_{\theta_0}(\theta)$. Par (29), on a l'égalité $\theta - \theta_0 = v + \rho(v)$ avec $\|\rho(v)\| \leq C_1\|v\|^2$. On en déduit que $\|v\|$ et $\|\theta - \theta_0\|$ sont comparables. En effet, l'inégalité triangulaire appliquée à $v = (\theta - \theta_0) - \rho(v)$ donne

$$\|\theta - \theta_0\| \geq \|v\| - \|\rho(v)\| \geq \|v\| - C_1\|v\|^2 = \|v\|(1 - C_1\|v\|).$$

Pour $\|v\| \leq \frac{1}{2C_1}$ (v très petit), le facteur $1 - C_1\|v\|$ est minoré par $\frac{1}{2}$, d'où $\|\theta - \theta_0\| \geq \frac{1}{2}\|v\|$, soit $\|v\| \leq 2\|\theta - \theta_0\|$. En reportant cette borne dans $\|\rho(v)\| \leq C_1\|v\|^2$,

$$\|\rho(v)\| \leq C_1(2\|\theta - \theta_0\|)^2 = 4C_1\|\theta - \theta_0\|^2 = O(\|\theta - \theta_0\|^2).$$

(iii) *Projection.* On applique $P_{T_{\theta_0}}^g$ aux deux membres de $\theta - \theta_0 = v + \rho(v)$. Par linéarité, la projection se distribue sur la somme : $P_{T_{\theta_0}}^g(\theta - \theta_0) = P_{T_{\theta_0}}^g v + P_{T_{\theta_0}}^g \rho(v)$. On traite les deux termes séparément.

— *Terme tangent.* Comme $v = \text{Log}_{\theta_0}(\theta)$ appartient déjà à $T_{\theta_0}\mathcal{S}_{m,S}^+$, il est invariant par la projection : $P_{T_{\theta_0}}^g v = v$.

— *Terme de reste.* Par définition de la norme d'opérateur puis par l'étape (ii), $\|P_{T_{\theta_0}}^g \rho(v)\| \leq \|P_{T_{\theta_0}}^g\|_{\text{op}} \|\rho(v)\| = O(\|\theta - \theta_0\|^2)$, la norme d'opérateur $\|P_{T_{\theta_0}}^g\|_{\text{op}}$ étant finie.

En sommant les deux, et puisque $v = \text{Log}_{\theta_0}(\theta)$,

$$P_{T_{\theta_0}}^g(\theta - \theta_0) = \text{Log}_{\theta_0}(\theta) + O(\|\theta - \theta_0\|^2). \quad \square$$

8.3 Cohérence des deux projections

La proposition 8.1 s'applique en particulier à chacune des deux métriques étudiées : les deux projections approchent donc le même logarithme riemannien, et leur écart mutuel est nécessairement d'ordre 2. Nous en donnons néanmoins une démonstration directe, que nous jugeons intéressante : elle n'utilise pas le logarithme riemannien et fait apparaître l'origine géométrique du phénomène, à savoir que la composante normale de $\theta - \theta_0$ est elle-même quadratiquement petite dès lors que les deux points sont sur la sous-variété.

Proposition 8.2 (Cohérence des deux projections). *Soient P_1 et P_2 les projecteurs orthogonaux sur $T_{\theta_0}\mathcal{S}_{m,S}^+$ associés à deux métriques distinctes (par exemple euclidienne et Fisher–Rao). Il existe $\delta > 0$ et une constante $C > 0$ tels que, pour tout $\theta \in \mathcal{S}_{m,S}^+$ vérifiant $\|\theta - \theta_0\| < \delta$, on ait*

$$\|P_1(\theta - \theta_0) - P_2(\theta - \theta_0)\| \leq C\|\theta - \theta_0\|^2.$$

Les deux approximations du logarithme riemannien coïncident donc à un terme d'ordre 2 près.

Démonstration. Posons $h = \theta - \theta_0$ et décomposons-le selon l'espace tangent en θ_0 et son orthogonal (par rapport au produit scalaire euclidien ici) : $h = h_{\parallel} + h_{\perp}$, avec $h_{\parallel} \in T_{\theta_0}\mathcal{S}_{m,S}^+$ et $h_{\perp} \in (T_{\theta_0}\mathcal{S}_{m,S}^+)^{\perp}$.

(i) *Les deux projecteurs coïncident sur l'espace tangent.* La cible de la projection, l'espace tangent $T_{\theta_0}\mathcal{S}_{m,S}^+ = \{W : dS(\theta_0)[W] = 0\}$, ne dépend d'aucun produit scalaire. P_i pousse h vers la cible orthogonalement au sens de sa propre métrique. Or un vecteur déjà tangent est laissé invariant par toute projection sur l'espace tangent, quelle que soit la direction de projection. Donc $P_1(h_{\parallel}) = h_{\parallel} = P_2(h_{\parallel})$, et la différence des deux projecteurs ne porte que sur la composante normale :

$$P_1(h) - P_2(h) = (P_1(h_{\parallel}) - P_2(h_{\parallel})) + (P_1(h_{\perp}) - P_2(h_{\perp})) = (P_1 - P_2)(h_{\perp}).$$

Il suffit d'imaginer h déjà sur l'espace tangent : les projections ne changeront rien, d'où le résultat. Rappelons bien sûr que les projections sont des applications linéaires.

(ii) *La composante normale est d'ordre 2.* Les deux points θ_0 et $\theta = \theta_0 + h$ sont sur la sous-variété (sans oublier que θ est suffisamment proche de θ_0 par hypothèse), donc S prend la même valeur en chacun : $S(\theta_0 + h) = S(\theta_0) = 1$. On développe S à l'ordre 2 autour de θ_0 :

$$S(\theta_0 + h) = S(\theta_0) + dS(\theta_0)[h] + \frac{1}{2}d^2S(\theta_0)[h, h] + O(\|h\|^3),$$

où $dS(\theta_0)[\cdot]$ est la différentielle première et $d^2S(\theta_0)[\cdot, \cdot]$ la hessienne. En soustrayant $S(\theta_0) = 1$ et en utilisant $S(\theta_0 + h) = 1$, le membre de gauche s'annule :

$$dS(\theta_0)[h] = -\frac{1}{2}d^2S(\theta_0)[h, h] + O(\|h\|^3). \quad (30)$$

Lien entre le terme linéaire et la composante normale. Par définition de l'espace tangent, $dS(\theta_0)[h_{\parallel}] = 0$, donc $dS(\theta_0)[h] = dS(\theta_0)[h_{\perp}]$. De plus, la différentielle s'écrit comme un produit scalaire avec le gradient, $dS(\theta_0)[h] = \langle \nabla S(\theta_0), h \rangle$ (métrique euclidienne pour le gradient), et le gradient $\nabla S(\theta_0)$ est précisément la direction normale. En effet, $dS(\theta_0)[h_{\parallel}] = \langle \nabla S(\theta_0), h_{\parallel} \rangle = 0$. Donc le gradient de S en θ_0 est dans l'orthogonal de l'espace tangent, $h_{\perp}$ aussi, et cet espace est une droite de dimension 1. Par conséquent $|dS(\theta_0)[h]| = |\langle \nabla S(\theta_0), h_{\perp} \rangle| = \|\nabla S(\theta_0)\| \|h_{\perp}\|$.

Majoration. La matrice hessienne $H = \nabla^2 S(\theta_0)$ associée à $d^2S(\theta_0)$ est symétrique. On peut donc la diagonaliser sous la forme $H = U \text{diag}(\lambda_i) U^{\top}$, où U est une matrice orthogonale. En posant $y = U^{\top}h$, la forme quadratique s'écrit $d^2S(\theta_0)[h, h] = h^{\top} H h = \sum_i \lambda_i y_i^2$. En posant $M = \|H\|_{\text{op}} = \max_k |\lambda_k|$, on majore

$$|d^2S(\theta_0)[h, h]| \leq \sum_i |\lambda_i| y_i^2 \leq M \sum_i y_i^2 = M \|y\|^2 = M \|h\|^2.$$

En reportant cette borne dans (30), on obtient $\|\nabla S(\theta_0)\| \|h_\perp\| \leq \frac{1}{2}M\|h\|^2 + O(\|h\|^3)$. Comme $\nabla S(\theta_0) \neq 0$ (hypothèse (A2)), on divise :

$$\|h_\perp\| \leq \frac{M}{2\|\nabla S(\theta_0)\|} \|h\|^2 + O(\|h\|^3) \leq C'\|h\|^2$$

pour $\|h\|$ assez petit. Rester sur la contrainte force donc la composante normale à être quadratiquement petite.

(iii) *Conclusion.* En combinant (i) et (ii),

$$\begin{aligned} \|P_1(h) - P_2(h)\| &= \|(P_1 - P_2)(h_\perp)\| \leq \|P_1 - P_2\|_{\text{op}} \|h_\perp\| \\ &\leq \underbrace{\|P_1 - P_2\|_{\text{op}} C'}_{\triangleq C} \|h\|^2, \end{aligned}$$

où $\|P_1 - P_2\|_{\text{op}}$ est une constante finie, la norme d'opérateur étant définie par

$$\|A\|_{\text{op}} \triangleq \sup_{x \neq 0} \frac{\|A(x)\|}{\|x\|}.$$

□

Remarque 8.1. D'après la proposition 8.1 appliquée à chacune des deux métriques, le logarithme riemannien vérifie $\text{Log}_{\theta_0}(\theta) = P_i(\theta - \theta_0) + O(\|\theta - \theta_0\|^2)$, $i = 1, 2$. Les deux projections approchent donc le même logarithme, exactes au premier ordre, et leur écart mutuel est d'ordre 2 (proposition 8.2). L'ambiguïté du choix de base, le vecteur e_d différent d'une métrique à l'autre, n'affecte que ce terme d'ordre 2. Pour la borne de Cramér–Rao, de nature infinitésimale, cette majoration garantit que le choix de métrique ne modifie pas la borne au premier ordre pertinent : le terme correctif contribue à des ordres asymptotiquement négligeables lorsque $\theta \rightarrow \theta_0$.

Bilan de la partie théorique

Cette partie a mis en place le cadre géométrique complet de l'estimation sur la sous-variété contrainte $\mathcal{S}_{m,S}^+$: caractérisation de l'espace tangent pour les trois fonctions d'échelle, projections orthogonales explicites dans les métriques euclidienne et de Fisher–Rao, construction de la forme bilinéaire de Fisher à partir de la seule différentielle du score, et assemblage des matrices $P_{\mathcal{E}}(V)$ et $F(V)$. La cohérence de l'approximation du logarithme riemannien par projection garantit enfin que la borne de Cramér–Rao intrinsèque peut être évaluée indépendamment du choix de métrique, à l'ordre pertinent. Ces éléments fournissent tout le nécessaire à l'étape suivante : la validation numérique des résultats par simulations de Monte-Carlo, qui fait l'objet des deux parties qui suivent. Il est question de savoir, après les avoir caractérisées, quelle métrique est la plus pertinente parmi les deux étudiées et comment elles diffèrent.

Note sur le cas gaussien. Les parties II et III se placent dans le modèle gaussien centré, qui est le cas particulier $g(t) = (2\pi)^{-m/2}e^{-t^2/2}$ des lois RES de la section 6. On a alors $\psi(t) = 1$ et $t \sim \chi_m^2$, d'où $\mathbb{E}\{t^2\psi(t)^2\} = m(m+2)$ et, par (22), $\alpha_g = 1$ (condition (7) bien vérifiée puisque $1 > m/(m+2)$). Le second terme de (6) disparaît, la métrique de Fisher–Rao se réduit à $\langle A, B \rangle_V = \frac{1}{2} \text{tr}(V^{-1}AV^{-1}B)$, et les corrections k de (11) et (14), proportionnelles à $\alpha - 1$, s'annulent : les normales du tableau du §4.4 deviennent $VE_{11}V$, V^2 et V . Ce sont ces expressions particularisées que l'on retrouvera au §11.4.

Deuxième partie

Méthodologie numérique et algorithmes d'estimation

9 Présentation du problème

9.1 Cadre statistique et géométrie

On considère n observations $\{\mathbf{x}_i\}_{i=1}^n$ indépendantes et identiquement distribuées, m -dimensionnelles, centrées et gaussiennes,

$$\mathbf{x}_i \sim \mathcal{N}(0, \Sigma), \quad \Sigma \in \mathcal{S}_m^+,$$

où $\mathcal{S}_m^+$ désigne l'ensemble des matrices $m \times m$ symétriques définies positives. Dans toutes les expériences menées, $m = 5$. La matrice Σ joue le rôle de matrice de dispersion. Elle encode simultanément l'échelle globale (la taille et l'étalement du nuage de données) et la structure de corrélation des données (la forme et la manière dont les variables évoluent ensemble). En géométrie de l'information, on cherche à séparer ces deux aspects. C'est le rôle de la fonction d'échelle S et de la matrice de forme $V = \Sigma/S(\Sigma)$ définies en (1), dont on reprend ici les hypothèses (A1)–(A3) du §1.2. La matrice de forme est l'objet estimé. Par homogénéité, $S(V) = S(\Sigma)/S(\Sigma) = 1$, si bien que V appartient à l'ensemble $\mathcal{S}_{m,S}^+$, qui constitue une sous-variété différentiable de dimension

$$\dim \mathcal{S}_{m,S}^+ = \dim \mathcal{S}_m - 1 = \frac{m(m+1)}{2} - 1 = 14.$$

9.2 La borne que l'on cherche à vérifier

L'estimation de V étant restreinte à la sous-variété $\mathcal{S}_{m,S}^+$, la borne de Cramér–Rao pertinente est la version intrinsèque (27) valable sur une variété riemannienne. En notant $C(\hat{V}_n, V)$ la matrice de covariance de l'estimateur (mesurée dans une base orthonormée de l'espace tangent, à partir de l'application logarithme, cf. (26)), $F(V)$ la matrice d'information de Fisher restreinte à l'espace tangent, et $P_{\mathcal{E}}(V)$ la représentation matricielle de la projection orthogonale sur l'espace tangent (section 7), on dispose de l'inégalité

$$C(\hat{V}_n, V) \succeq \frac{1}{n} (P_{\mathcal{E}}(V) F(V) P_{\mathcal{E}}(V))^{\dagger} + \text{termes de courbure}, \quad (31)$$

où $\dagger$ désigne la pseudo-inverse de Moore–Penrose et où le facteur $1/n$ traduit la décroissance de la variance avec le nombre d'observations. On cherche à comparer numériquement, en fonction de n , la trace des deux membres de l'inégalité. En pratique, la base tangente étant construite orthonormée, le facteur $P_{\mathcal{E}}(V)$ devient l'identité sur cette base et la borne se réduit à $n^{-1} \text{tr} F(V)^{-1}$.

Cette même projection est notée $P_{TV\mathcal{S}_{m,S}^+}^{gV}(\cdot)$ dans toute la suite, sous la forme d'un opérateur agissant directement sur les matrices de $\mathcal{S}_m$ (cf. (9)), plutôt que sous sa représentation matricielle $P_{\mathcal{E}}(V)$ dans la base tangente orthonormée.

9.3 Pourquoi comparer plusieurs contraintes

Les trois fonctions d'échelle classiques étudiées sont celles de (2),

$$S_1(\Sigma) = [\Sigma]_{11}, \quad S_2(\Sigma) = \frac{1}{m} \text{tr}(\Sigma), \quad S_3(\Sigma) = \det(\Sigma)^{1/m}.$$

À chacune correspond une sous-variété $\mathcal{S}_{m,S}^+$ distincte, donc un espace tangent, une projection et une courbure différents. Comme la borne de Cramér–Rao dépend de cette géométrie, comparer les trois contraintes revient à déterminer quelle normalisation conduit à une estimation la mieux

conditionnée et à une borne plus fidèlement atteinte. Chaque contrainte est de plus étudiée sous les deux métriques riemanniennes de la partie I : la métrique euclidienne (5) et la métrique de Fisher–Rao gaussienne

$$\langle A, B \rangle_V = \frac{1}{2} \text{tr} (V^{-1} A V^{-1} B), \quad (32)$$

c'est-à-dire la métrique (6) pour $\alpha = \alpha_g = 1$.

Trois matrices de covariance représentatives ont été testées : l'identité I_m , une matrice auto-régressive $[C_{\text{AR}}]_{ij} = \rho^{|i-j|}$ avec $\rho = 0,5$, et une matrice définie positive $M = AA^\top + \frac{1}{2}I_m$ (avec A tirée selon une loi normale centrée réduite).

10 L'estimateur naturel

Pour des données gaussiennes centrées, l'estimateur le plus immédiat de la matrice de covariance est la matrice de covariance empirique (SCM)

$$\hat{\Sigma}_n = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top. \quad (33)$$

Cet estimateur est non biaisé, $\mathbb{E}[\hat{\Sigma}_n] = \Sigma$, et coïncide avec l'estimateur du maximum de vraisemblance de Σ dans le modèle gaussien non contraint. L'estimateur naturel de la matrice de forme s'en déduit par la même normalisation que (1) :

$$\hat{V}_n = \frac{\hat{\Sigma}_n}{S(\hat{\Sigma}_n)} \in \mathcal{S}_{m,S}^+. \quad (34)$$

Bien que $\hat{\Sigma}_n$ soit un estimateur sans biais, l'absence de biais ne se transmet pas à $\hat{V}_n$. En effet, la normalisation par $S(\hat{\Sigma}_n)$ introduit un biais sur la matrice de forme. Ce biais peut être l'une des explications de l'écart résiduel observé aux petites tailles d'échantillon dans la partie III.

11 Éléments de calcul pour l'optimisation

11.1 De la vraisemblance à la fonction de coût

Pour déterminer l'estimateur du maximum de vraisemblance (MLE) contraint à la sous-variété, on exprime la vraisemblance jointe des n observations gaussiennes :

$$L(V) = \prod_{i=1}^n |V|^{-1/2} (2\pi)^{-m/2} \exp \left(-\frac{1}{2} \mathbf{x}_i^\top V^{-1} \mathbf{x}_i \right),$$

d'où la log-vraisemblance

$$\log L(V) = -\frac{nm}{2} \log(2\pi) - \frac{n}{2} \log |V| - \frac{1}{2} \sum_{i=1}^n \mathbf{x}_i^\top V^{-1} \mathbf{x}_i.$$

Le terme quadratique se réécrit en trace grâce à $\mathbf{x}_i^\top V^{-1} \mathbf{x}_i = \text{tr}(V^{-1} \mathbf{x}_i \mathbf{x}_i^\top)$ et à la linéarité de la trace :

$$\sum_{i=1}^n \mathbf{x}_i^\top V^{-1} \mathbf{x}_i = \text{tr} \left(V^{-1} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top \right) = n \text{tr} (V^{-1} \hat{\Sigma}_n),$$

où $\hat{\Sigma}_n$ est la matrice de covariance empirique (33). Ainsi,

$$\log L(V) = -\frac{nm}{2} \log(2\pi) - \frac{n}{2} \left[\log |V| + \text{tr} (V^{-1} \hat{\Sigma}_n) \right].$$

11.2 Maximiser L revient à minimiser f

Maximiser L équivaut à maximiser $\log L$, la fonction $\log$ étant strictement croissante, donc à minimiser $-\log L$. Or $-\log L$ est, à une constante additive $\frac{nm}{2} \log(2\pi)$ et à un facteur multiplicatif positif $\frac{n}{2}$ près, égale à

$$f(V) = \frac{1}{2} \left(\log |V| + \text{tr}(V^{-1} \hat{\Sigma}_n) \right). \quad (35)$$

Ni la constante additive ni le facteur multiplicatif positif ne modifient le point minimisant. On peut donc les supprimer sans changer l'*argmin*. La fonction (35) est précisément la log-vraisemblance négative normalisée que l'on minimise. C'est elle qu'implémente `neg_log_lik_mean`.

11.3 Calcul du gradient ambiant

On dérive maintenant entièrement le gradient de f . On note $\Sigma := \hat{\Sigma}_n$ pour alléger les notations. La différentielle de la fonction de coût s'obtient en combinant les différentielles de ses termes constitutifs évaluées en V dans une direction de perturbation $H \in \mathcal{S}_m$.

Tout d'abord, pour le terme lié au déterminant, l'utilisation de l'équivalent $\log |I + M| = \text{tr}(M) + o(\|M\|)$ permet d'écrire un développement limité à l'ordre un : $\log |V + tH| = \log (|V| |I + tV^{-1}H|) = \log |V| + \text{tr}(tV^{-1}H) + o(t)$. En identifiant le terme linéaire en t , on obtient

$$d(\log |V|)[H] = \text{tr}(V^{-1}H). \quad (36)$$

Ensuite, la différentielle de l'inverse a déjà été obtenue en (19) en différenciant $VV^{-1} = I$ dans la direction H , ce qui donne $d(V^{-1})[H] = -V^{-1}HV^{-1}$.

Enfin, pour le terme de trace, l'utilisation du résultat (19) avec à l'invariance cyclique de la trace conduit à la relation

$$d(\text{tr}(V^{-1}\Sigma))[H] = \text{tr}(d(V^{-1})[H]\Sigma) = -\text{tr}(V^{-1}HV^{-1}\Sigma) = -\text{tr}(V^{-1}\Sigma V^{-1}H). \quad (37)$$

En combinant (36) et (37), la différentielle de f dans la direction H s'écrit

$$df(V)[H] = \frac{1}{2} \left(\text{tr}(V^{-1}H) - \text{tr}(V^{-1}\Sigma V^{-1}H) \right) = \text{tr}(G(V)H),$$

où l'on a identifié, par la relation $df(V)[H] = \text{tr}(G(V)H)$ propre au produit scalaire euclidien $\text{tr}(A^\top B)$ (avec G symétrique), le gradient ambiant

$$G(V) = \frac{1}{2}(V^{-1} - V^{-1}\Sigma V^{-1}). \quad (38)$$

C'est exactement ce que retourne `ambient_gradient_mean`. On remarque au passage que $G(V) = -\frac{1}{n} \sum_i \Lambda(\mathbf{x}_i)$, où Λ est le score (45) : le gradient de la log-vraisemblance négative est bien l'opposé de la moyenne des scores, ce qui est cohérent avec la théorie du maximum de vraisemblance.

11.4 Projection orthogonale et gradient riemannien

La projection orthogonale sur l'espace tangent, notée $P_{T_V \mathcal{S}_{m,S}^+}^{g_V}$ et construite à la section 4, intervient à deux titres. D'abord pour approcher l'application logarithme (43) dans le calcul de la covariance. Ensuite pour extraire la composante tangente du gradient ambiant afin d'obtenir le gradient riemannien. Ce dernier est l'unique vecteur tangent représentant la différentielle au sens de la métrique choisie :

$$\nabla_{\mathcal{M}} f(V) = P_{T_V \mathcal{S}_{m,S}^+}^{g_V}(G(V)). \quad (39)$$

Dans notre implémentation, la projection employée pour l'optimisation s'effectue toujours selon la métrique euclidienne (`project_tangent(G, V, scale_type, 'euclidien')`).

Les six expressions utilisées par le code sont celles établies à la section 4, dans la cas gaussien $\alpha_g = 1$. On les rassemble ici pour la lecture.

Contrainte	$P_{T_V \mathcal{S}_{m,S}^+}^{gV}(A)$, métrique euclidienne	$P_{T_V \mathcal{S}_{m,S}^+}^{gV}(A)$, métrique de Fisher–Rao
S_1	$A - [A]_{11} E_{11}$	$A - \frac{[A]_{11}}{[V]_{11}^2} V E_{11} V$
S_2	$A - \frac{\text{tr}(A)}{m} I_m$	$A - \frac{\text{tr}(A)}{\text{tr}(V^2)} V^2$
S_3	$A - \frac{\text{tr}(V^{-1}A)}{\text{tr}(V^{-2})} V^{-1}$	$A - \frac{\text{tr}(V^{-1}A)}{m} V$

La colonne euclidienne est celle du bilan du §4.4. La colonne Fisher–Rao s’obtient en reportant les normales $VE_{11}V$, V^2 et V dans (8)–(9) avec la métrique (32).

Rétraction sur la variété. Après un pas de descente selon la direction du gradient riemannien, le point intermédiaire $Y = V_k - \gamma \nabla_{\mathcal{M}} f(V_k)$ appartient à l’espace tangent, mais n’est en général plus sur la variété $\mathcal{S}_{m,S}^+$. Il est impératif de le ramener sur celle-ci par l’intermédiaire d’une *rétraction*, que nous noterons $R_{\mathcal{M}}$. Il est fondamental de distinguer cette opération (qui relie l’espace tangent à la variété) de la projection orthogonale $P_{T_V \mathcal{S}_{m,S}^+}^{gV}$ (qui agit de l’espace ambiant vers l’espace tangent).

Dans notre cadre, la rétraction est définie comme la projection métrique au sens de la norme de Frobenius :

$$R_{\mathcal{M}}(Y) = \arg \min_{V: S(V)=1} \|V - Y\|_F^2. \quad (40)$$

Détaillons la résolution de ce problème d’optimisation sous contrainte pour chacune des trois fonctions d’échelle.

- **Contrainte S_1 .** La contrainte impose $[V]_{11} = 1$. Puisque la norme de Frobenius au carré $\|V - Y\|_F^2 = \sum_{i,j} (V_{ij} - Y_{ij})^2$ est additive composante par composante, la minimisation par rapport aux éléments libres $(i, j) \neq (1, 1)$ conduit trivialement à $V_{ij} = Y_{ij}$. Le seul élément contraint est fixé à 1. La solution exacte s’obtient donc en forçant simplement le premier élément diagonal, ce qui s’écrit analytiquement

$$V = Y - ([Y]_{11} - 1) E_{11}. \quad (41)$$

- **Contrainte S_2 .** La contrainte impose $\text{tr}(V) = m$. L’ensemble admissible étant affine, on utilise la méthode des multiplicateurs de Lagrange avec le lagrangien $\mathcal{L}(V, \lambda) = \frac{1}{2} \|V - Y\|_F^2 + \lambda(\text{tr}(V) - m)$. L’annulation du gradient par rapport à V donne

$$\nabla_V \mathcal{L} = V - Y + \lambda I_m = 0 \implies V = Y - \lambda I_m.$$

Pour trouver le multiplicateur λ , on réinjecte V dans la contrainte : $\text{tr}(Y - \lambda I_m) = m \implies \text{tr}(Y) - \lambda m = m \implies \lambda = \frac{\text{tr}(Y) - m}{m}$. La rétraction admet donc bien une solution analytique, qui correspond à une translation globale de la diagonale :

$$V = Y - \frac{\text{tr}(Y) - m}{m} I_m. \quad (42)$$

- **Contrainte S_3 .** La contrainte impose $\det(V) = 1$. L’ensemble admissible est cette fois non linéaire. En posant le lagrangien $\mathcal{L}(V, \lambda) = \frac{1}{2} \|V - Y\|_F^2 + \lambda(\det(V) - 1)$ et en utilisant l’identité différentielle du déterminant $\nabla_V \det(V) = \det(V) V^{-1}$, on obtient la condition du premier ordre $V - Y + \lambda \det(V) V^{-1} = 0$. Sachant que $\det(V) = 1$, on peut multiplier l’équation à droite par V pour obtenir une équation matricielle du second degré :

$$V^2 - YV + \lambda I_m = 0.$$

Cette équation impose en particulier $YV = V^2 + \lambda I_m$, dont le membre de droite est symétrique. On en déduit que Y et V commutent. Deux matrices symétriques qui commutent sont diagonalisables dans une même base. Ainsi, il existe donc une base orthonormée commune U telle que $Y = U\Lambda_Y U^\top$ (la décomposition spectrale de Y , déjà connue) et $V = UDU^\top$, avec $D = \text{diag}(d_1, \dots, d_m)$ à déterminer. C'est d'ailleurs exactement ce que fait le code (`eigh(Y)`) puis recherche des nouvelles valeurs propres dans la même base).

En reportant ces décompositions dans l'équation matricielle, celle-ci se diagonalise en m équations scalaires (une par valeur propre) : $d_i^2 - \lambda_i d_i + \lambda = 0$, $i = 1, \dots, m$, dont on retient la racine positive

$$d_i(\lambda) = \frac{\lambda_i + \sqrt{\lambda_i^2 - 4\lambda}}{2}.$$

Le problème est ainsi réduit à la recherche du zéro d'une unique fonction scalaire de la variable λ :

$$h(\lambda) \triangleq \prod_{i=1}^m d_i(\lambda) - 1 = 0.$$

Cette équation n'admet pas de solution analytique dès que $m \geq 3$. Néanmoins, chaque $d_i(\lambda)$ étant strictement décroissante en λ sur son domaine de validité $\lambda \leq \min_i(\lambda_i^2)/4$, la fonction h l'est également, ce qui garantit l'existence d'au plus un zéro. C'est ce zéro que l'on estime par la méthode de Brent, comme implémenté dans la fonction `retract`.

12 Critères d'évaluation et de comparaison

12.1 Covariance empirique des estimateurs

Pour estimer le membre de gauche de l'inégalité pour un estimateur donné $\hat{V}_n$, on part de la définition (26) de la covariance de $\hat{V}_n$ mesurée dans une base orthonormée $\{e_i\}$ de l'espace tangent :

$$[C(\hat{V}_n, V)]_{ij} = \mathbb{E}\{\langle \log_V(\hat{V}_n), e_i \rangle_V \langle \log_V(\hat{V}_n), e_j \rangle_V\},$$

où $\log_V : \mathcal{S}_{m,S}^+ \rightarrow T_V \mathcal{S}_{m,S}^+$ est l'application logarithme au point V . L'application logarithme n'ayant pas d'expression analytique simple, on utilise son approximation linéaire, justifiée par la proposition 8.1 :

$$\log_V(\hat{V}_n) \approx P_{T_V \mathcal{S}_{m,S}^+}^{g_V}(\hat{V}_n - V), \quad (43)$$

c'est-à-dire la projection orthogonale (au sens de la métrique g_V choisie) de l'écart $\hat{V}_n - V$ sur l'espace tangent. La trace de la covariance s'obtient alors comme la moyenne, sur m_C tirages de Monte-Carlo, de la norme au carré de ce projeté :

$$\text{tr } \hat{C}(\hat{V}_n, V) = \frac{1}{m_C} \sum_{t=1}^{m_C} \langle \delta^{(t)}, \delta^{(t)} \rangle_V, \quad \delta^{(t)} = P_{T_V \mathcal{S}_{m,S}^+}^{g_V}(\hat{V}_n^{(t)} - V), \quad (44)$$

où $\hat{V}_n^{(t)}$ correspond à la valeur de l'estimateur calculée sur un nouveau jeu de données lors du t -ième tirage indépendant de la simulation. En effet, la trace de C vaut $\sum_i [C]_{ii} = \mathbb{E}\{\sum_i \langle \log_V(\hat{V}_n), e_i \rangle_V^2\} = \mathbb{E}\{\|\log_V(\hat{V}_n)\|_V^2\}$ par l'identité de Parseval dans la base orthonormée $\{e_i\}$, d'où (44). C'est exactement ce que calcule la fonction `empirical_trace_C`. La proposition 8.2 garantit par ailleurs que le choix de la métrique dans (43) n'affecte cette quantité qu'au second ordre.

12.2 Matrice d'information de Fisher

Le membre de droite de l'inégalité requiert la matrice de Fisher restreinte à l'espace tangent, telle que définie en (16) : $[F(V)]_{ij} = \mathbb{E}\{d\ell(V)[e_i] d\ell(V)[e_j]\}$, où $d\ell(V)[\cdot]$ est la différentielle de la

log-vraisemblance. Pour une observation gaussienne centrée, la log-vraisemblance s'écrit

$$\log p(\mathbf{x} \mid V) = -\frac{m}{2} \log(2\pi) - \frac{1}{2} \log |V| - \frac{1}{2} \mathbf{x}^\top V^{-1} \mathbf{x}.$$

En différenciant dans une direction $H \in \mathcal{S}_m$ et en utilisant les identités $d(\log |V|)[H] = \text{tr}(V^{-1}H)$ et $d(V^{-1})[H] = -V^{-1}HV^{-1}$ (démontrées précédemment), on obtient

$$d\ell(V)[H] = -\frac{1}{2} \text{tr}(V^{-1}H) + \frac{1}{2} \mathbf{x}^\top V^{-1}HV^{-1}\mathbf{x} = \text{tr} \left(\underbrace{\left(-\frac{1}{2}V^{-1} + \frac{1}{2}V^{-1}\mathbf{x}\mathbf{x}^\top V^{-1} \right)}_{\Lambda(\mathbf{x})} H \right),$$

où l'on a réécrit la forme quadratique en trace via $\mathbf{x}^\top A\mathbf{x} = \text{tr}(A\mathbf{x}\mathbf{x}^\top)$. La matrice symétrique

$$\Lambda(\mathbf{x}) = -\frac{1}{2}V^{-1} + \frac{1}{2}V^{-1}\mathbf{x}\mathbf{x}^\top V^{-1} \quad (45)$$

correspond au score gaussien (fonction `gaussian_score`) (c'est le cas $\psi \equiv 1$ du score RES (20)).

La composante du score le long de e_i vaut $d\ell(V)[e_i] = \text{tr}(\Lambda(\mathbf{x})e_i)$. La matrice de Fisher est alors estimée par Monte-Carlo,

$$\hat{F}(V) = \frac{1}{n_{\text{FR}}} \sum_{k=1}^{n_{\text{FR}}} \mathbf{s}^{(k)} (\mathbf{s}^{(k)})^\top, \quad s_i^{(k)} = \text{tr}(\Lambda(\mathbf{x}^{(k)})e_i), \quad (46)$$

avec $\mathbf{x}^{(k)} \sim \mathcal{N}(0, V)$ et $n_{\text{FR}} = 1000$ tirages. C'est ce que réalise la fonction `fisher_matrix_tangent`. Comme $\{e_i\}$ est orthonormée, $\hat{F}$ est directement la représentation de la forme de Fisher dans cette base.

12.3 Comparaison avec la borne

La matrice $\hat{F}(V)$ ainsi obtenue est la Fisher *par observation* : pour n observations indépendantes, elle est multipliée par n et l'inégalité matricielle s'écrit $C \succeq \frac{1}{n} \hat{F}(V)^{-1}$. Or cette inégalité au sens de l'ordre matriciel implique mathématiquement l'inégalité sur les traces :

$$\text{tr}(C) \geq \frac{1}{n} \text{tr}(\hat{F}(V)^{-1}). \quad (47)$$

Ce passage à la trace est pertinent. D'un point de vue statistique, il revient à borner l'erreur quadratique moyenne (MSE) totale de l'estimateur dans l'espace tangent. D'un point de vue pratique, il permet de réduire l'inégalité matricielle à une inégalité scalaire représentable graphiquement. On trace donc, en fonction de n , la courbe empirique $\text{tr} \hat{C}(\hat{V}_n, V)$ issue de (44) et la courbe théorique

$$\frac{1}{n} \text{tr} \hat{F}(V)^{-1}. \quad (48)$$

La validation consiste à vérifier que la première domine la seconde et suit la même décroissance en $1/n$.

13 Maximum de vraisemblance par descente de gradient euclidienne

13.1 Principe et rôle du pas

La minimisation de f s'effectue par une descente itérative de la forme $V_{k+1} = V_k - \gamma_k g_k$, où g_k est une direction de descente (le gradient) et $\gamma_k > 0$ le pas d'apprentissage. La suite (V_k) converge alors vers un point stationnaire $\nabla f = 0$, qui est précisément l'estimateur du maximum de vraisemblance recherché. Le pas γ gouverne le compromis entre vitesse et stabilité et doit être choisi correctement.

13.2 Choix du pas par backtracking

Le code fixe le pas par un algorithme de *backtracking*. En partant de $\gamma_0 = 1$, on réduit $\gamma \leftarrow \beta\gamma$ (avec $\beta = 0,5$) tant que la condition de décroissance suffisante

$$f(V_{k+1}) \leq f(V_k) - c\gamma\|g_k\|^2, \quad c = 10^{-4},$$

n'est pas satisfaite ou tant que la matrice candidate n'est pas définie positive. Le critère d'arrêt combine un nombre maximal d'itérations ($N = 50$) et un seuil sur la norme du gradient tangent ($\|g_k\|^2 < 10^{-7}$), en dessous duquel l'itération est jugée stationnaire.

13.3 Insuffisance de la descente euclidienne naïve

Une descente euclidienne naïve $V_{k+1} = V_k - \gamma G_k$ pose une difficulté car V doit satisfaire la contrainte $S(V) = 1$. En effet, le pas $-\gamma G_k$ n'est pas tangent à $\mathcal{S}_{m,S}^+$: il possède une composante normale qui fait quitter la sous-variété ($S(V_{k+1}) \neq 1$). Par ailleurs, rien ne garantit que V_{k+1} reste dans le cône $\mathcal{S}_m^+$. Il faut donc systématiquement restreindre la direction de descente à l'espace tangent et ramener le point mis à jour sur la variété.

14 Maximum de vraisemblance par descente de gradient stochastique

14.1 Du gradient complet au gradient stochastique

La descente de gradient classique repose, à chaque itération, sur le gradient ambiant (38) $G(V) = \frac{1}{2}(V^{-1} - V^{-1}\hat{\Sigma}_n V^{-1})$, qui fait intervenir l'estimateur naturel $\hat{\Sigma}_n = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top$, exprimé avec la totalité des n observations.

La descente de gradient stochastique remplace, à chaque pas, la moyenne sur les n observations par une moyenne sur un sous-ensemble tiré au hasard. Une motivation principale la justifie : lorsque n est grand, évaluer le gradient complet à chaque pas devient coûteux, alors qu'un gradient partiel reste bon marché et relativement précis.

14.2 Gradient de mini-batch

On partitionne à chaque époque les indices $\{1, \dots, n\}$ en mini-batches $\mathcal{B}$ de taille $|\mathcal{B}| = b$ (ici $b = 30$), obtenus par permutation aléatoire. À chaque mini-batch on associe la SCM partielle $\hat{\Sigma}_{\mathcal{B}} = \frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \mathbf{x}_i \mathbf{x}_i^\top$, puis le gradient de mini-batch

$$\nabla f_{\mathcal{B}}(V) \triangleq G_{\mathcal{B}}(V) = \frac{1}{2}(V^{-1} - V^{-1}\hat{\Sigma}_{\mathcal{B}} V^{-1}). \quad (49)$$

Pour un échantillon fixé, un mini-batch tiré uniformément sans remise vérifie $\mathbb{E}_{\mathcal{B}}[\hat{\Sigma}_{\mathcal{B}}] = \hat{\Sigma}_n$. Par linéarité de (49) en $\hat{\Sigma}_{\mathcal{B}}$, il vient

$$\mathbb{E}_{\mathcal{B}}[\nabla f_{\mathcal{B}}(V)] = G(V) = \nabla f(V), \quad (50)$$

c'est-à-dire que $\nabla f_{\mathcal{B}}(V)$ est un estimateur sans biais du gradient complet, dont la variance décroît lorsque b augmente. Le paramètre b gouverne ainsi le compromis entre la précision et le coût : un lot petit rend chaque pas peu coûteux mais bruité, un lot grand le rend coûteux mais représentatif.

14.3 Adaptation géométrique

L'adaptation au cadre riemannien est identique à celle de la descente complète et ne requiert aucune construction nouvelle. Le gradient ambiant de mini-batch est projeté sur l'espace tangent pour fournir le gradient riemannien de mini-batch $\nabla_{\mathcal{M}} f_{\mathcal{B}}(V) = P_{TV\mathcal{S}_{m,S}^+}^{g_V}(G_{\mathcal{B}}(V))$, au moyen de la

même projection euclidienne. Le pas $Y = V - \gamma_k \nabla_{\mathcal{M}} f_{\mathcal{B}}(V)$ est ensuite ramené sur la variété par la rétraction $V \leftarrow R_{\mathcal{M}}(Y)$ déjà définie en (40), et n'est accepté que s'il préserve la positivité. La contrainte $S(V) = 1$ est donc respectée exactement à chaque pas.

Trois différences seulement séparent cette version de la descente complète. Premièrement, le gradient est évalué sur un mini-batch (49), non sur l'échantillon complet. Deuxièmement, le pas suit une suite décroissante fixée $\gamma_k = \gamma_0/(1+k)$, où k compte les pas stochastiques cumulés, au lieu d'être choisi par *backtracking*. Enfin, une époque correspond à un passage complet sur tous les mini-batches. Les paramètres retenus sont $b = 30$, $\gamma_0 = 1$ et 50 époques, les autres réglages étant ceux du MLE complet. On notera enfin que, tant que $n \leq b$, chaque époque ne comporte qu'un unique lot égal à l'échantillon entier.

15 Maximum de vraisemblance par descente de gradient naturel

15.1 Le gradient dépend de la métrique choisie

Les approches précédentes construisent toutes leur direction de descente à partir du gradient ambiant, ramené sur l'espace tangent par la projection euclidienne. Ce choix n'est pas neutre. L'objet central du problème est la différentielle $df(V)[\cdot]$, qui est une forme linéaire sur $T_V \mathcal{S}_{m,S}^+$. Le gradient, quant à lui, est le vecteur qui la représente au sens d'un produit scalaire donné,

$$df(V)[H] = \langle \nabla f(V), H \rangle, \quad \forall H \in T_V \mathcal{S}_{m,S}^+. \quad (51)$$

Changer de produit scalaire change donc le gradient sans changer la fonction ni son minimiseur, mais en changeant la trajectoire de la descente. Les algorithmes précédents retiennent le produit scalaire euclidien, hérité de l'espace ambiant $\mathcal{S}_m$.

15.2 Le gradient naturel

La métrique de Fisher admet, dans la base tangente orthonormée $\{e_i\}_{i=1}^p$ ($p = \dim \mathcal{S}_{m,S}^+ = 14$), la représentation matricielle $F(V)$ définie en (24). Le gradient naturel est le gradient au sens de cette métrique :

$$\langle \nabla^{\text{nat}} f(V), H \rangle_F = df(V)[H], \quad \forall H \in T_V \mathcal{S}_{m,S}^+. \quad (52)$$

En notant $\mathbf{g} \in \mathbb{R}^p$ le vecteur des coordonnées de la différentielle dans la base tangente, $g_i = df(V)[e_i] = \text{tr}(G(V)e_i)$, la résolution de (52) donne

$$\nabla^{\text{nat}} f(V) = \sum_{i=1}^p (F(V)^{-1} \mathbf{g})_i e_i. \quad (53)$$

On peut faire une comparaison avec la descente classique. Là où celle-ci se déplace selon $-\nabla f = -\mathbf{g}$, la descente naturelle se déplace selon $-\nabla^{\text{nat}} f = -F^{-1} \mathbf{g}$. La matrice de Fisher rééchelonne chaque direction tangente en fonction de l'information qu'elle porte sur le modèle.

15.3 Comparaison avec la descente classique

Un argument explique pourquoi le gradient naturel est susceptible d'accélérer la convergence. En effet, la matrice de Fisher est l'espérance de la hessienne de la log-vraisemblance négative, $F(V) = \mathbb{E}\{-\nabla^2 \log p(\mathbf{x} \mid V)\}$, et f n'est autre que cette log-vraisemblance négative normalisée. Pour un grand nombre d'observations, $\nabla^2 f \approx F$ et le pas $-F^{-1} \mathbf{g}$ est donc un pas de Newton approché. On attend en conséquence une convergence beaucoup plus rapide que la convergence linéaire de la descente de gradient classique.

En contrepartie, le coût numérique devient plus important. Chaque itération exige désormais, outre la projection tangente, le calcul de la matrice $F(V)$ de taille $p \times p$, puis la résolution du système $F \mathbf{h} = \mathbf{g}$, en $O(p^3)$. Comme $p \sim m^2/2$, le coût par itération passe de $O(m^3)$ à $O(m^6)$. De plus, F dépend de V et doit donc être recalculée à chaque itération. Le gradient naturel a donc un coût par itération plus élevé, mais un nombre d'itérations plus faible.

15.4 Adaptation géométrique et réglages

Comme pour la version stochastique, l'adaptation au cadre contraint ne requiert aucune construction nouvelle. La direction naturelle est par construction tangente, puisqu'elle est exprimée dans la base $\{e_i\}$ de $T_V \mathcal{S}_{m,S}^+$. Le pas $Y = V - \gamma_k \nabla^{\text{nat}} f(V)$ est ramené sur la variété par la rétraction $V \leftarrow R_{\mathcal{M}}(Y)$ définie précédemment, et n'est accepté que s'il préserve la positivité. La contrainte $S(V) = 1$ reste donc satisfaite à chaque itération.

Le *backtracking* est conservé, mais la norme du gradient est simplement remplacée par sa norme naturelle :

$$f(V_{k+1}) \leq f(V_k) - c \gamma \mathbf{g}^\top F(V_k)^{-1} \mathbf{g}, \quad c = 10^{-4}, \quad \beta = 0,5, \quad \gamma_0 = 1,$$

et le critère d'arrêt combine 50 itérations et le seuil $\mathbf{g}^\top F^{-1} \mathbf{g} < 10^{-7}$. Tous les autres réglages sont ceux du MLE complet.

Troisième partie

Résultats numériques et comparaison des estimateurs

16 Méthodologie de l'analyse et grille de lecture

16.1 L'écart relatif comme unique critère

Les résultats numériques obtenus sont rassemblés dans les tableaux 2, 3, 4 et 5. L'analyse qui suit repose sur un unique indicateur, l'*écart relatif moyen signé* entre la trace empirique de l'erreur quadratique et la borne théorique :

$$\varepsilon = \frac{\text{tr } \widehat{C}(\widehat{V}_n, V) - \frac{1}{n} \text{tr } F(V)^{-1}}{\frac{1}{n} \text{tr } F(V)^{-1}}. \quad (54)$$

Une valeur positive signale une variance empirique au-dessus de la borne (borne valide mais non atteinte). Une valeur proche de zéro signale une borne atteinte, c'est-à-dire un estimateur efficace. Une valeur légèrement négative traduit le bruit de Monte-Carlo autour d'une borne exactement atteinte. Employer la même définition (54) pour l'estimateur naturel, pour le MLE complet, pour sa version stochastique et pour sa version à gradient naturel unifie l'analyse et rend les quatre estimateurs directement comparables.

Le critère du « nombre de tailles n pour lesquelles l'inégalité est respectée », utilisé dans une version antérieure de ce rapport, a été abandonné. Cette métrique mesure de quel côté de la borne tombe une quantité estimée sur un nombre fini m_C de réalisations de Monte-Carlo. Ainsi, si l'erreur quadratique moyenne passe en dessous de la borne, cela ne constitue pas un problème théorique mais numérique : c'est uniquement dû au nombre d'essais de Monte-Carlo.

16.2 Ordre de grandeur du bruit de Monte-Carlo

Afin d'interpréter correctement le signe et l'amplitude de l'écart relatif, il faut tenir compte du bruit statistique inhérent à la méthode de Monte-Carlo. L'erreur quadratique empirique est calculée sur $m_C = 300$ réalisations dans un espace de dimension 14. En assimilant l'erreur à un vecteur gaussien, la variance relative de cette moyenne est de l'ordre de $2/(m_C \times 14)$, soit un écart-type relatif de

$$\sigma_{\text{rel}} \approx \sqrt{\frac{2}{300 \times 14}} \approx 2\%.$$

Cela définit une marge de tolérance d'environ ± 4 à $\pm 5\%$ autour de la borne. Par conséquent, tout écart mesuré à l'intérieur de cette bande indique que la borne est atteinte, le signe n'étant alors qu'une fluctuation aléatoire. Seules les valeurs sortant nettement de cette zone traduisent une vraie inefficacité de l'estimateur.

16.3 Grille de lecture

Quatre comportements ont été observés dans les simulations numériques.

TABLE 1 – Grille de lecture de l'écart relatif ε adoptée dans l'analyse.

Valeur de ε	Interprétation
$ \varepsilon \lesssim 5\%$, signe fluctuant, stable en n	Borne atteinte : estimateur efficace. Le signe n'est pas interprétable.
$\varepsilon > 0$ de quelques dizaines de %, stable ou décroissant en n	Borne valide mais non atteinte : inefficacité réelle, due aux petits échantillons ou à l'optimiseur.
$\varepsilon > 0$ croissant avec n	Pas de décroissance en $1/n$: un plancher de variance.
ε de différents ordres de grandeur	Moyenne dominée par quelques trajectoires divergentes : instabilité. L'analyse doit se faire sur les courbes.

Remarque 16.1. Les légendes portées dans les figures produites par le code renvoient à « l'équation (13) », il s'agit de la borne théorique (48) du rapport actuel.

17 Estimateur naturel

17.1 Écart relatif et comportement asymptotique

Les figures « Trace en fonction de n » présentent toutes le même comportement d'ensemble : une décroissance monotone en $1/n$, rapide aux petites tailles puis de plus en plus lente. La courbe empirique (verte) et la borne théorique (rouge) deviennent indiscernables aux grandes tailles. La figure 1a illustre le cas le plus favorable. Les deux courbes se superposent presque exactement sur toute la plage $n \in [100, 5000]$, signe d'un estimateur efficace atteignant la borne. La figure 1b présente au contraire une courbe empirique qui reste nettement au-dessus de la borne aux petites tailles avant de la rejoindre. Cela traduit une variance excédentaire de l'estimateur, mais qui respecte l'inégalité.

Les valeurs du tableau 2 confirment cette lecture. Pour les contraintes S_2 et S_3 , l'écart est faible, de l'ordre de 1 à 8 % en métrique euclidienne et de 0 à 4 % en métrique de Fisher–Rao. Ces valeurs se trouvent à l'intérieur ou au voisinage immédiat de la bande de bruit définie au §16.2. La borne est donc atteinte. À l'opposé, un excès de +27 à +42 % sous la contrainte S_1 sort largement de la bande de bruit. Ces valeurs révèlent une borne valide, mais une estimation inefficace.

Concernant l'évolution en fonction de n , l'écart relatif reste stable sur toute la plage, sans dérive. La variance empirique et la borne décroissent de la même manière en $1/n$. Ce point est important pour la suite, car c'est précisément cette stabilité de ε en fonction de n qui fera défaut à la version stochastique (§19.1).

Enfin, la métrique de Fisher–Rao produit systématiquement des écarts inférieurs ou égaux à ceux de la métrique euclidienne. Ce résultat est cohérent avec le fait que la métrique de Fisher–Rao est la métrique intrinsèque et adaptée au modèle : elle mesure l'erreur dans la géométrie même où la borne est formulée.

TABLE 2 – Estimateur naturel. Écart relatif moyen signé ε (%), moyenné sur 13 tailles $n \in [100, 5000]$.

Matrice	Contrainte	Écart relatif ε (%)	
		Métrique euclidienne	Métrique Fisher–Rao
Identité	S_1	+27,64	+27,64
	S_2	−1,83	−1,83
	S_3	−0,14	−0,14
Auto-régr.	S_1	+36,87	+27,77
	S_2	+4,06	+1,38
	S_3	+3,64	−0,14
SDP aléat.	S_1	+41,72	+27,03
	S_2	+7,95	+3,97
	S_3	+5,09	−0,14

17.2 Influence de la contrainte géométrique

La comparaison des trois fonctions d'échelle est ici la plus nette, puisqu'aucun optimiseur n'intervient.

Les contraintes S_2 et S_3 restent toutes deux au voisinage de la borne. En particulier, S_3 présente une précision remarquable en métrique de Fisher–Rao ($\varepsilon \approx -0,14$), ce qui suggère une efficacité liée à la géométrie induite par $\det V = 1$. La contrainte S_1 fournit au contraire les résultats les moins intéressants : normaliser par une unique entrée constitue une contrainte de mauvaise qualité, car elle propage la variance de cet élément dans toute la matrice. L'estimateur reste valide, mais il est franchement inefficace.

Le rôle du conditionnement apparaît clairement lorsqu'on lit le tableau 2 colonne par colonne. En métrique euclidienne, l'écart croît systématiquement avec le mauvais conditionnement de la matrice à estimer, en passant de l'identité à la matrice auto-régressive, puis à la matrice SDP aléatoire : $-1,83$, $+4,06$, $+7,95$ pour S_2 ; $-0,14$, $+3,64$, $+5,09$ pour S_3 ; $+27,64$, $+36,87$, $+41,72$ pour S_1 . En métrique de Fisher–Rao, cette croissance disparaît totalement pour S_3 et S_1 et partiellement pour S_2 . Autrement dit, une part de la dégradation observée en métrique euclidienne n'est pas une propriété de l'estimateur mais de la métrique employée pour le juger. La métrique intrinsèque absorbe le mauvais conditionnement. Ce qui subsiste sous S_1 , en revanche, est peut être un défaut propre à la normalisation. Par exemple, l'excès de $+27\%$ persiste pour l'identité et en métrique de Fisher–Rao, là où ni le conditionnement de la matrice ni le choix de la métrique ne peuvent être mis en cause.




FIGURE 1 – Estimateur naturel, matrice SDP aléatoire.

17.3 Dynamique de convergence et stabilité

L'estimateur naturel $\hat{V}_n = \hat{\Sigma}_n / S_i(\hat{\Sigma}_n)$ possède une forme analytique : il ne comporte aucune itération, de sorte que la question de la monotonie d'une suite $f(V_k)$ ne se pose pas.

Sous S_1 , le dénominateur $[\hat{\Sigma}_n]_{11}$ est une variable aléatoire scalaire dont les fluctuations se répercutent sur toute la matrice. Ici aucune itération ne l'amplifie, mais cette sensibilité deviendra une explication des divergences observées sous gradient stochastique (§19.2).

Il faut enfin souligner un point qui structure la suite du rapport : $V_0 = \hat{\Sigma}_n / S_i(\hat{\Sigma}_n)$ est le point d'initialisation des trois descentes étudiées par la suite. Les valeurs du tableau 2 ne décrivent donc pas seulement un estimateur concurrent, elles donnent le point de départ des optimiseurs. Toute la lecture des sections suivantes consiste à comparer l'écart final d'une descente à l'écart initial : +27 à +42 % (sous S_1), -2 à +8 % (sous S_2), -0,14 à +5 % (sous S_3). La distance parcourue par l'optimiseur se lit directement dans cette différence.

18 MLE par descente de gradient euclidienne

18.1 Écart relatif et comportement asymptotique

Sous la contrainte de trace S_2 , le MLE se tient exactement sur la borne. L'écart est de faible amplitude et oscille autour de zéro selon la matrice et la métrique (de -2,82 % à +0,75 %). Toutes ces valeurs tiennent dans la bande de bruit du §16.2. La figure 2b confirme l'alignement de la courbe empirique avec la borne sur toute la plage d'étude.

Les contraintes S_1 et S_3 présentent au contraire un écart positif et hors bande. La trace empirique reste au-dessus de la borne, avec un écart modéré mais systématique, atteignant +37,88 % pour SDP S_1 en métrique euclidienne et +26,06 % pour SDP S_3 . Cet écart se concentre aux petites tailles (jusqu'à $n = 40$ environ), où la courbe empirique domine nettement la borne avant de la rejoindre (figure 2a). Cet écart décroît avec n et ne traduit donc aucune instabilité, mais un biais aux petits échantillons.

La métrique de Fisher–Rao resserre là encore les écarts de façon marquée : +3,38 % contre +15,84 % pour Auto-régressive S_1 , +14,10 % contre +37,88 % pour SDP S_1 , +12,42 % contre +26,06 % pour SDP S_3 . Le rapport entre les deux métriques est ici bien plus grand que pour l'estimateur naturel. On notera d'ailleurs le contraste avec le §17.2. En effet, pour l'estimateur naturel, la métrique de Fisher – Rao absorbait entièrement la croissance de S_1 avec le conditionnement (+27,64, +27,77, +27,03). Elle ne l'absorbe que partiellement dans ce cas (-1,73, +3,38, +14,10). Ce qui résiste à la métrique de Fisher – Rao est donc la part imputable à l'optimiseur.

Une interprétation peut être annoncée dès maintenant et sera établie au §20.1 : l'écart mesuré ici sous S_1 est en partie dû à l'optimiseur employé.

TABLE 3 – MLE contraint par descente de gradient riemannienne euclidienne. Écart relatif moyen signé ε (%), moyenné sur 13 tailles $n \in [15, 150]$.

Matrice	Contrainte	Écart relatif ε (%)	
		Métrique euclidienne	Métrique Fisher–Rao
Identité	S_1	-1,73	-1,73
	S_2	-2,47	-2,47
	S_3	+12,42	+12,42
Auto-régr.	S_1	+15,84	+3,38
	S_2	+0,75	-2,82
	S_3	+22,80	+12,42
SDP aléat.	S_1	+37,88	+14,10
	S_2	+0,72	-1,89
	S_3	+26,06	+12,42

18.2 Influence de la contrainte géométrique

La comparaison des trois fonctions d'échelle fait ressortir la contrainte de trace S_2 comme la plus convaincante dans ce mode d'optimisation. Elle réunit les écarts les plus faibles, en tenant sur la borne dès $n = 15$. Cette supériorité s'explique géométriquement. La contrainte $\text{tr}(W) = 0$ est linéaire et définit un hyperplan de normale I_m . Ainsi la projection tangente et la rétraction ont des formules simples et fermées, et la géométrie est isotrope.

La contrainte du déterminant S_3 occupe une position intermédiaire. Elle reste valide sur toute la plage mais laisse subsister un excès positif aux petites tailles. Le comportement de cet écart selon la métrique est intéressant. En métrique de Fisher–Rao il se fige à +12,42 % exactement pour les trois matrices, tandis qu'en métrique euclidienne il croît avec le mauvais conditionnement (+12,42 %, +22,80 %, puis +26,06 % de l'identité à la matrice SDP). Cette croissance de 13,6 points est donc entièrement absorbée par la métrique intrinsèque. En revanche, ce qui subsiste est un excès de +12,42 % présent y compris pour l'identité, c'est-à-dire dans la configuration la mieux conditionnée. Il ne peut donc pas être imputé à l'optimiseur, ce que confirmera le §20.2 : il s'agit d'un biais de petit échantillon. La contrainte S_3 est ainsi excellente en régime asymptotique, mais bien moins efficace que S_2 aux petites tailles.

C'est la contrainte S_1 qui concentre l'essentiel des difficultés. Elle est celle dont l'écart croît le plus vite avec le mauvais conditionnement de la matrice à estimer (−1,73 %, +15,84 %, +37,88 % en euclidien, de l'identité à la matrice SDP). Normaliser par une unique entrée crée en effet une géométrie très déformée que l'optimiseur ne sait pas gérer. La conséquence pratique est décrite au §18.3. La descente est lente, et 50 itérations ne suffisent pas à atteindre l'optimum lorsque la matrice à estimer est mal conditionnée. Cette inefficacité n'est donc pas irrémédiable, comme on le verra à la section 20.




FIGURE 2 – MLE à gradient euclidien, matrice SDP aléatoire.

18.3 Dynamique de convergence et stabilité

La figure 3 représente l'évolution de la log-vraisemblance négative $f(V_k)$ au fil des 50 itérations, pour les trois contraintes superposées et $n = 30$. Le comportement global est celui d'une descente monotone, sans oscillation ni remontée. En effet, à aucune itération la fonction de coût ne croît, ce qui atteste du bon fonctionnement du *backtracking*. Les trois courbes convergent vers des plateaux distincts, ce qui est attendu car chaque contrainte définit un problème de minimisation différent.

Les dynamiques diffèrent nettement selon la contrainte, et ces différences rejoignent l'analyse du §18.2.

La contrainte S_2 atteint son plateau en moins de cinq itérations, sans état transitoire visible. Cette convergence quasi immédiate découle directement de la simplicité géométrique de sa projection linéaire, qui rend chaque pas efficace.

La contrainte S_1 présente au contraire l'état transitoire le plus long. Par exemple, pour la matrice auto-régressive, $f(V_k)$ décroît de façon prononcée sur une vingtaine d'itérations avant de se stabiliser. En réalité, $f(V_k)$ plafonne mais l'itéré V_k continue d'évoluer très lentement. Cette lenteur traduit le mauvais conditionnement de la contrainte. Puisque la descente n'a pas terminé son parcours à 50 itérations, il y a des écarts excessifs pour les petites tailles d'échantillon.

La contrainte S_3 occupe une position particulière car sa courbe est plate et à un niveau de f supérieur aux deux autres. Ce n'est pas une erreur numérique mais un résultat, démontré en (55) : le point initial $V_0 = \hat{\Sigma}_n/S_3(\hat{\Sigma}_n)$ est exactement le maximum de vraisemblance contraint par S_3 .

Enfin, l'initialisation joue ici un rôle décisif, qu'il est utile de quantifier en confrontant les tableaux 2 et 3 sous S_1 en métrique euclidienne : partant d'un écart initial de +27,64 %, la descente aboutit à -1,73 % pour l'identité ; partant de +36,87 % elle aboutit à +15,84 % pour la matrice auto-régressive ; partant de +41,72 % elle aboutit à +37,88 % pour la matrice SDP. Ce résultat n'est pas paradoxal. En effet, l'équivalence entre l'estimateur naturel et le MLE contraint est asymptotique ($n \rightarrow \infty$), et non valable à taille finie.




FIGURE 3 – Convergence du MLE à gradient euclidien ($n = 30$) : log-vraisemblance négative $f(V_k)$ en fonction de l'itération, pour les trois contraintes.

19 MLE par descente de gradient stochastique

19.1 Écart relatif et comportement asymptotique

La différence avec le MLE complet est prononcée, et s'avère très variable selon la contrainte choisie. Sous S_3 , les écarts (+11,36 %, +20,79 %, +23,23 % en euclidien) restent proches des valeurs de la descente complète (+12,42 %, +22,80 %, +26,06 % en euclidien). L'invariance quasi exacte de l'écart Fisher-Rao autour de +11 % (+11,29 %, +11,31 %, +10,40 %) indépendamment de la matrice testée prolonge celle déjà observée pour la descente complète. Les courbes (figure 4a) montrent une trace empirique décroissant en $1/n$, légèrement au-dessus de la borne aux petites tailles avant de la rejoindre.

Sous S_2 , en revanche, l'effondrement est remarquable hors du cas de l'identité. Pour l'identité, l'estimateur reste efficace car les écarts relatifs pour les deux métriques sont dans la bande de bruit. Pour les matrices auto-régressive et SDP, les écarts atteignent +246,87 % et +379,56 % en euclidien, +718,74 % et +8805,84 % en Fisher-Rao.

L'analyse décisive est asymptotique, et se lit sur les courbes plutôt que sur les moyennes. La figure 4b montre que la trace empirique ne décroît pas en $1/n$. Elle plafonne à un niveau élevé pendant que la borne continue de décroître. Ainsi, l'écart relatif croît fortement avec n . C'est le troisième comportement de la grille de lecture (tableau 1) : un plancher de variance. Le bruit du

gradient stochastique et l'absence de *backtracking* empêchent l'itéré de converger vers le MLE. On remarque que la métrique de Fisher–Rao ne resserre plus rien dans ces cas et donne même des valeurs supérieures à la métrique euclidienne. Ce n'est pas étrange, puisque l'estimateur n'étant plus au voisinage du paramètre à estimer, la comparaison entre métriques n'est plus informative. Ce comportement n'est toutefois pas reproductible d'un tirage à l'autre, comme le montre le §21.3.

Enfin, sous S_1 , les moyennes s'échelonnent de $6 \times 10^3 \%$ à $1,7 \times 10^8 \%$. Ces valeurs ne sont pas des mesures d'écart. Elles sont entièrement dues à de rares trajectoires très divergentes. Les courbes (figure 5) montrent en effet une trace empirique proche de la borne pour la plupart des n , mais présentant des pics isolés atteignant 10^5 à 10^7 . Une seule valeur aberrante suffit à faire exploser la moyenne. C'est le signe du dernier comportement du tableau 1. Dans ce cas, la moyenne doit être abandonnée et on s'intéresse plutôt à l'examen des trajectoires.

TABLE 4 – MLE contraint par descente de gradient stochastique. Écart relatif moyen signé ε (%), moyenné sur 13 tailles $n \in [15, 150]$.

Matrice	Contrainte	Écart relatif ε (%)	
		Métrique euclidienne	Métrique Fisher–Rao
Identité	S_1	$+6,0 \times 10^3$	$+5,6 \times 10^3$
	S_2	$-5,21$	$-5,22$
	S_3	$+11,36$	$+11,29$
Auto-régr.	S_1	$+1,4 \times 10^6$	$+2,1 \times 10^7$
	S_2	$+246,87$	$+718,74$
	S_3	$+20,79$	$+11,31$
SDP aléat.	S_1	$+1,7 \times 10^8$	$+4,0 \times 10^7$
	S_2	$+379,56$	$+8805,84$
	S_3	$+23,23$	$+10,40$

19.2 Influence de la contrainte géométrique

La hiérarchie des contraintes se trouve renversée par rapport à la descente complète. La contrainte S_2 , qui dominait le cas précédent, cesse d'être la plus fiable, tandis que la contrainte S_3 devient la seule robuste. L'explication tient entièrement à la distance que la descente doit parcourir depuis son initialisation.

Sous S_3 , puisque l'estimateur initial $V_0 = \hat{\Sigma}_n / S_3(\hat{\Sigma}_n)$ est exactement l'optimum contraint (55), la descente stochastique ne parcourt qu'une distance minimale et le bruit de mini-batch n'a pratiquement rien altéré. $\hat{V}_n$ reste très proche de l'estimateur naturel efficace.

Sous S_2 , tout dépend de la matrice à estimer. Pour l'identité, la forme vraie est $V = I$ et $V_0 \approx I$. La descente ne bouge quasiment pas et reste efficace. Pour les matrices mal conditionnées, la descente doit parcourir une distance bien plus grande (car le point de départ est loin de l'optimum), et c'est sur ce trajet que le bruit de mini-batch crée le plancher de variance décrit au §19.1. Le bon conditionnement géométrique de S_2 , qui suffisait à la descente complète, ne suffit plus ici. Dans notre cas, c'est un problème d'optimiseur, plus particulièrement de contrôle de pas.

Sous S_1 , l'origine de la chute est la même que précédemment : une perturbation de l'entrée $(1, 1)$ suivie de la rétraction imposée engendre un redimensionnement global de la matrice. La fragilité identifiée pour la descente complète est amplifiée par les itérations de la descente de gradient stochastique.




FIGURE 4 – MLE stochastique, matrice SDP aléatoire.




FIGURE 5 – MLE stochastique, contrainte S_1 .

19.3 Dynamique de convergence, stabilité et influence du pas

La figure 6 présente $f(V_k)$ au fil des 50 époques, pour $n = 30$ et les trois contraintes superposées. Comme $n = 30 = b$, l'unique lot contient l'intégralité des données. La stochasticité véritable n'apparaîtrait que pour $n > 30$, et la descente est ici une descente classique mais avec un pas décroissant. Cette configuration est idéale pour étudier l'impact du pas sur la convergence. Trois comportements se dégagent.

Pour l'identité, la courbe S_1 présente un pic à la première époque puis se stabilise rapidement, S_2 se fixe en moins de cinq époques, et S_3 reste immobile à un plateau supérieur. Toutes sont stables, conformément au bon conditionnement de l'identité pour les trois contraintes. Pour la matrice SDP, S_3 demeure basse et stable, mais S_2 hésite puis diverge brutalement vers l'époque 48.

Ce décrochage tardif est la conséquence de l'absence de contrôle du pas d'apprentissage. Ce phénomène, totalement absent de la descente complète dont la monotonie est garantie par le *backtracking*, témoigne d'un manque de régulation de l'optimisation. La version stochastique accepte tous les pas proposés, sans jamais vérifier que f décroît. La descente complète rejetait tout pas augmentant f , ce qui amortissait les divergences décrites au §19.2. On notera que ce décrochage apparaît même à $n = 30$, où le mini-batch contient l'intégralité des données et où le gradient n'est donc pas bruité. C'est donc bien le contrôle de pas, et non le bruit de mini-batch, qui est un problème.

L'impact de l'initialisation est ici très déterminant, car elle détermine si la trajectoire imposée par le pas aboutira à la cible ou si elle divergera.




FIGURE 6 – Convergence du MLE stochastique ($n = 30$) : log-vraisemblance négative $f(V_k)$ en fonction de l'époque.

20 MLE par descente de gradient naturel

20.1 Écart relatif et comportement asymptotique

Le contraste avec la version stochastique est frappant. Là où le gradient stochastique dégradait le MLE complet partout sauf sous S_3 , le gradient naturel l'améliore ou le laisse inchangé.

Le résultat le plus visible concerne en effet la contrainte S_1 . Les excès considérables du MLE complet deviennent des écarts faibles : $-1,84\%$ et $-1,23\%$ en euclidien, $-4,60\%$ et $-3,31\%$ en Fisher–Rao. Toutes ces valeurs tiennent dans la bande de bruit de Monte-Carlo du §16.2 et la borne est donc atteinte. Les courbes (figure 9) le confirment. La trace empirique et la borne sont pratiquement superposées sur toute la plage, y compris aux petits échantillons.

L'apport de cet optimiseur sur la contrainte S_1 est notoire. La comparaison des trois méthodes est éloquente :

Matrice (S_1 , euclidien)	Estimateur naturel	MLE euclidien	MLE naturel
Identité	+27,64 %	−1,73 %	−3,68 %
Auto-régr.	+36,87 %	+15,84 %	−1,84 %
SDP aléat.	+41,72 %	+37,88 %	−1,23 %

Pour l'identité, bien conditionnée, la descente euclidienne parcourait déjà la totalité du chemin. Pour la matrice auto-régressive elle n'en parcourait qu'environ la moitié. Pour la matrice SDP, la plus mal conditionnée, à peine un dixième. Quant au gradient naturel, il parcourt le chemin entier dans les trois cas. C'est le comportement attendu du préconditionnement par $F(V)^{-1}$: elle permet d'atténuer la dégradation liée au mauvais conditionnement de la matrice à estimer.

TABLE 5 – MLE contraint par descente de gradient naturel. Écart relatif moyen signé ε (%), moyenné sur 13 tailles $n \in [15, 150]$.

Matrice	Contrainte	Écart relatif ε (%)	
		Métrieque euclidienne	Métrieque Fisher–Rao
Identité	S_1	−3,68	−3,68
	S_2	−2,23	−2,23
	S_3	+12,42	+12,42
Auto-régr.	S_1	−1,84	−4,60
	S_2	+1,36	−2,71
	S_3	+22,80	+12,42
SDP aléat.	S_1	−1,23	−3,31
	S_2	+1,05	−2,89
	S_3	+26,06	+12,42

20.2 Influence de la contrainte géométrique

Le gradient naturel agit de façon différente selon la contrainte.

Pour la première contrainte, la géométrie induite par $[V]_{11} = 1$ est fortement anisotrope. La multiplication par $F(V)^{-1}$ rétablit l’isotropie (une courbure égale dans toutes les directions).

Pour la deuxième contrainte, aucun changement notable n’est à remarquer. Les écarts passent de −2,47 %, +0,75 %, +0,72 % à −2,23 %, +1,36 %, +1,05 % en euclidien, et de −2,47 %, −2,82 %, −1,89 % à −2,23 %, −2,71 %, −2,89 % en Fisher–Rao. Les différences, inférieures à un point de pourcentage, s’expliquent entièrement par le bruit de Monte-Carlo attendu pour $m_C = 300$ tirages (ce n’est pas réellement un grand nombre de tirages, mais au-delà les simulations devenaient trop longues). Cette absence de changement était prévisible du fait de la géométrie induite par S_2 . C’est rassurant, car le gradient naturel ne dégrade pas ce qui était déjà efficace, et son gain se concentre exclusivement sur les géométries mal conditionnées.

Pour la troisième contrainte, les six valeurs sont identiques au centième près à celles du MLE complet. Cette coïncidence n’est pas un hasard. En effet, le point de départ V_0 est exactement le MLE contraint par S_3 . Minimiser f sous $\det V = 1$ annule le terme $\log |V|$ et revient à minimiser $\frac{1}{2} \text{tr}(V^{-1} \hat{\Sigma}_n)$. La condition de stationnarité s’écrit, avec un multiplicateur λ ,

$$V^{-1} \hat{\Sigma}_n V^{-1} = \lambda V^{-1} \iff V = \lambda^{-1} \hat{\Sigma}_n,$$

et la contrainte $\det V = 1$ impose $\lambda^{-1} = \det(\hat{\Sigma}_n)^{-1/m}$, soit

$$\hat{V}_n^{\text{ML}}|_{S_3} = \frac{\hat{\Sigma}_n}{\det(\hat{\Sigma}_n)^{1/m}} = \frac{\hat{\Sigma}_n}{S_3(\hat{\Sigma}_n)} = V_0. \quad (55)$$

Le gradient tangent est donc nul dès l’initialisation, et le gradient naturel reproduit le MLE euclidien à l’identique.

L’écart résiduel de +12,42 % à +26,06 % observé sous S_3 n’est donc sûrement pas propre à la méthode d’optimisation, mais à d’autres facteurs. L’identité (55) permet d’ailleurs de l’attribuer plus précisément : sous S_3 , l’estimateur naturel et le MLE contraint sont le *même* estimateur ; or le tableau 2, moyenné sur $n \in [100, 5000]$, donne −0,14 % en Fisher–Rao, tandis que le tableau 3, moyenné sur $n \in [15, 150]$, donne +12,42 %. La différence entre ces deux nombres ne peut provenir que de la plage de tailles : elle mesure directement le biais de petit échantillon, isolé de tout effet d’optimiseur, et confirme que l’excès résiduel s’évanouit lorsque n croît. Il faut y ajouter les termes de courbure négligés dans l’approximation linéaire de l’application logarithme (partie I).




FIGURE 7 – MLE à gradient naturel, matrice SDP aléatoire, contraintes S_3 et S_2 .

Une fois le préconditionnement par F^{-1} effectué, le choix de la fonction d'échelle cesse largement d'influer sur l'efficacité de l'estimation. Sous S_1 et sous S_2 , la borne est atteinte.

20.3 Dynamique de convergence et stabilité

La figure 8 présente $f(V_k)$ au fil des 50 itérations, pour $n = 30$ et les trois contraintes superposées, dans les mêmes conditions que la figure 3. La descente reste monotone, sans oscillation ni remontée. Le *backtracking* joue le même rôle régulateur que dans le cas euclidien. On n'observe rien de comparable aux décrochages de la version stochastique (figure 6).

La différence tient à la vitesse. Le régime transitoire de S_1 , qui occupait une vingtaine d'itérations pour la matrice auto-régressive sous descente euclidienne, se réduit ici à moins d'une dizaine. La courbe décroît abruptement puis se fige, et ce dans les trois configurations testées. C'est dû au caractère quasi newtonien du pas naturel. Les contraintes S_2 et S_3 conservent le comportement déjà décrit, c'est-à-dire un plateau atteint en quelques itérations pour S_2 , une courbe rigoureusement plate pour S_3 .

Sur le plan de la complexité, il faut construire et inverser $F(V)$ (14×14 ici) à chaque itération, soit $O(m^6)$ contre $O(m^3)$ par itération pour la descente euclidienne. Ce surcoût est compensé, pour S_1 , par la réduction du nombre d'itérations, mais il ne l'est en revanche pas pour S_2 ni pour S_3 , où le résultat est inchangé. Le gradient naturel n'est donc pas un choix systématiquement préférable : cette méthode est préférable pour les fonctions d'échelle mal conditionnées.




FIGURE 8 – Convergence du MLE à gradient naturel ($n = 30$) : log-vraisemblance négative $f(V_k)$ en fonction de l'itération, pour les trois contraintes.

21 Comparaison de l'évolution des quatre estimateurs sur un même graphique

21.1 Lecture par les courbes

Les tableaux 2 à 5 résument chaque configuration par une moyenne sur 13 tailles n , ce qui cache la différence entre un biais systématique et un accident ponctuel. Les figures 9 à 11 reprennent la matrice SDP aléatoire et superposent les traces empiriques des quatre estimateurs à la borne théorique, pour les trois contraintes et les deux métriques. Cette lecture directe permet de trancher ce que les moyennes seules ne permettaient pas de distinguer.

21.2 Contrainte S_1

C'est sous S_1 que les quatre courbes se distinguent le plus nettement (figure 9). Le MLE stochastique n'est pas stable. Malgré un départ proche des trois autres courbes jusqu'à $n = 30$, il décroche brutalement dès $n = 40$, avant de parfois revenir dans le lot. Cette alternance illustre, sur une réalisation, l'instabilité par trajectoires divergentes déjà identifiée au §19.1. À la différence du plancher de variance de S_2 , l'instabilité de S_1 se manifeste par des décrochages ponctuels et imprévisibles.

À l'inverse, l'estimateur naturel et le MLE à gradient euclidien restent parfaitement monotones sur toute la plage, mais au-dessus de la borne, avec un écart qui se referme progressivement (comme observé aux §17.1 et §18.1). Le MLE à gradient naturel est pratiquement confondu avec la borne dès le début dans les deux métriques.




FIGURE 9 – Comparaison des quatre estimateurs et de la borne théorique pour la matrice SDP sous S_1 .

21.3 Contrainte S_2

Sous S_2 (figure 10), les quatre courbes restent proches les unes des autres et de la borne sur l'essentiel de la plage, y compris le MLE stochastique. Le décrochage du SGD est très marqué pour la métrique de Fisher-Rao (autour de $n = 40, 75$ et 130). Les quatre courbes sont sinon superposées en dehors de ces valeurs.

Il faut préciser que les courbes de cette section proviennent d'une exécution distincte de celle des sections précédentes, identique en tous points hormis la graine du générateur aléatoire. On ne retrouve donc pas ici le comportement décrit au §19.1. Sous S_2 , la trace du MLE stochastique ne plafonne pas au-dessus de la borne sur toute la plage, mais la suit correctement en dehors de quelques tailles où elle décroche. Le plateau observé à la figure 4b et la moyenne de +8805,84 % du tableau 4 caractérisent donc un tirage particulier, et non le comportement général de la méthode.

Ce constat reste un résultat. Sous S_2 et pour une matrice mal conditionnée, la descente stochastique ne converge pas vers un régime stable : selon la réalisation, elle décroche tôt et reste bloquée, ou décroche tard et par intermittence. L'origine est la même dans les deux cas, à savoir l'absence de contrôle de pas décrite au §19.3. Puisque rien n'annonce le décrochage observé à l'époque 48, le fait qu'il survienne ou non avant la fin de l'horizon dépend de la trajectoire suivie. Les valeurs de S_1 et S_2 du tableau 4 doivent donc être lues comme celles d'une réalisation particulière, et seule la ligne S_3 , stable d'un tirage à l'autre, supporte une interprétation directe.




FIGURE 10 – Comparaison des quatre estimateurs et de la borne théorique pour la matrice SDP sous S_2 .

21.4 Contrainte S_3

Sous S_3 (figure 11), les quatre courbes sont indiscernables sur l'intégralité de la plage, dans les deux métriques. Cela confirme numériquement l'identité (55). Puisque le point de départ V_0 est déjà l'optimum contraint, aucune méthode d'optimisation ne peut produire un itéré différent. L'écart à la borne théorique reste bien visible aux petites tailles et se réduit avec n . Cet écart ne peut donc pas être attribué à l'optimiseur, car les quatre méthodes coïncident.




FIGURE 11 – Comparaison des quatre estimateurs et de la borne théorique pour la matrice SDP sous S_3 .

22 Conclusion expérimentale

Les simulations valident l'inégalité de Cramér–Rao intrinsèque dans le cas gaussien. Elles permettent également d'observer et de tirer différents enseignements.

(i) La métrique de Fisher–Rao donne des résultats plus concluants. Elle est intrinsèque au modèle gaussien. En effet, elle produit majoritairement des écarts inférieurs ou égaux à ceux de la métrique euclidienne. Elle parvient à atténuer la dégradation liée au mauvais conditionnement de la matrice à estimer.

(ii) La hiérarchie des fonctions d'échelle dépend de la méthode d'optimisation, et n'est jamais universelle. Cependant, on peut établir un classement des performances des différentes contraintes (S_1 , S_2 , S_3) sur la base de l'estimateur naturel. Ce choix se justifie par le fait que les différentes méthodes d'optimisation sont asymptotiquement équivalentes à l'estimateur naturel. Selon ce critère, c'est finalement la contrainte S_3 qui s'impose comme la plus performante. En effet, au-delà de sa propriété théorique qui rend l'optimisation immédiate, S_3 démontre une efficacité quasi parfaite sous les deux métriques. La contrainte S_2 offre également de très bonnes performances, mais avec des écarts relatifs légèrement plus accrus. Enfin, la contrainte S_1 se révèle inefficace pour la majeure partie des méthodes d'optimisation testées.

(iii) La démonstration et la vérification numérique de l'identité (55) sous la contrainte S_3 ont pu être établies. Les simulations sont en accord avec la démonstration faite de la relation (55), qui établit que sous la contrainte S_3 , le MLE est égal à l'estimateur naturel. Sur le plan expérimental, cela se traduit par le fait que les courbes d'erreur sont superposées et indiscernables pour tous les algorithmes testés. Le point de départ de l'optimisation constituant déjà l'optimum théorique, le gradient est nul dès l'initialisation. Les méthodes ne nécessitent donc aucune itération et convergent immédiatement. Les variations observées proviennent seulement de la taille de l'échantillon.

(iv) L'apport du gradient naturel a pu être observé. Sous la contrainte S_1 , où les descentes échouaient à converger en 50 itérations, le gradient naturel s'avère extrêmement efficace. Pour les autres contraintes, il ne dégrade pas ce qui était déjà efficace. Le préconditionnement par la matrice de Fisher adapte la géométrie de l'espace, ce qui permet à l'optimiseur de converger beaucoup plus rapidement ; le nombre d'itérations nécessaires est donc réduit. Néanmoins, ce gain a un coût, qui n'est pas rentabilisé pour les contraintes S_2 et S_3 .

Conclusion générale

Ce travail a parcouru la chaîne complète qui va de la définition géométrique de la matrice de forme à la validation numérique de la borne qui la concerne.

La partie théorique a montré que le passage du cône $\mathcal{S}_m^+$ à la sous-variété contrainte $\mathcal{S}_{m,S}^+$ se ramène, pour les trois fonctions d'échelle classiques, à l'identification d'une unique direction normale, et que la forme bilinéaire de Fisher se construit une seule fois sur $\mathcal{S}_m$, indépendamment de la contrainte et de la métrique. C'est ce qui rend l'étude numérique "praticable" : seule la base sur laquelle on évalue la forme change d'une configuration à l'autre. Le fait que la métrique de Fisher–Rao émerge du calcul du score est le résultat le plus "satisfaisant".

La partie numérique a ensuite confirmé, sur 36 configurations, que la borne de Cramér–Rao intrinsèque est respectée, et que les écarts observés peuvent être attribuer à trois causes différentes : le biais de petit échantillon, le mauvais conditionnement de la métrique employée pour juger, et le défaut de l'optimiseur. Cette distinction est, à nos yeux, le principal apport de l'étude : elle montre qu'un écart à la borne n'est pas en soi un verdict définitif sur l'estimateur.

Deux prolongements se dégagent naturellement. Le plus immédiat consiste à sortir du cas gaussien pour exploiter la généralité du modèle RES de la section 6. Le coefficient α_g deviendrait un paramètre, et l'on peut alors mesurer l'écart entre la métrique de Fisher–Rao et celle du cas gaussien. Un second prolongement porte sur les termes de courbure de (31), systématiquement négligés ici. Leur évaluation explicite permettrait de savoir si certains écarts observés leur est imputable ou non.

Références

- [1] F. Bouchard, A. Breloy, A. Collas, A. Renaux et G. Ginolhac, *The Fisher–Rao geometry of CES distributions*, dans *Elliptically Symmetric Distributions in Signal Processing and Machine Learning*, J.-P. Delmas, M. N. El Korso, S. Fortunati et F. Pascal (éd.), Springer Cham, 2024.
- [2] S. Fortunati, J.-P. Delmas et E. Ollila, *Nuisance parameters and elliptically symmetric distributions : a geometric approach to parametric and semiparametric efficiency*, 2026. Disponible sur arXiv : <https://arxiv.org/abs/2506.23213>.
- [3] J.-P. Delmas, *Background on real and complex elliptically symmetric distributions*, dans *Elliptically Symmetric Distributions in Signal Processing and Machine Learning*, Springer Cham, 2024. DOI 10.1007/978-3-031-52116-4_1. HAL : hal-04217510v3.
- [4] S. T. Smith, *Covariance, subspace, and intrinsic Cramér–Rao bounds*, IEEE Transactions on Signal Processing, vol. 53, no. 5, pp. 1610–1630, 2005.
- [5] N. Boumal, A. Singer, P.-A. Absil et V. D. Blondel, *Cramér–Rao bounds for synchronization of rotations*, Information and Inference, vol. 2, no. 1, pp. 1–51, 2013.
- [6] N. Boumal, *On intrinsic Cramér–Rao bounds for Riemannian submanifolds and quotient manifolds*, IEEE Transactions on Signal Processing, 2013.
- [7] P.-A. Absil et J. Malick, *Projection-like retractions on matrix manifolds*, SIAM Journal on Optimization, vol. 22, no. 1, pp. 135–158, 2012. DOI 10.1137/100802529. HAL : hal-00651608v2.
- [8] J. R. Magnus et H. Neudecker, *Matrix Differential Calculus with Applications in Statistics and Econometrics*, 3^e éd., Wiley, 2019.
- [9] D. Paindaveine, *A canonical definition of shape*, Statistics & Probability Letters, vol. 78, no. 14, pp. 2240–2247, 2008.
- [10] N. Boumal, *An Introduction to Optimization on Smooth Manifolds*, Cambridge University Press, 2023.